



# Engenharia de Dados com Hadoop e Spark

---



# Bem-vindo(a)





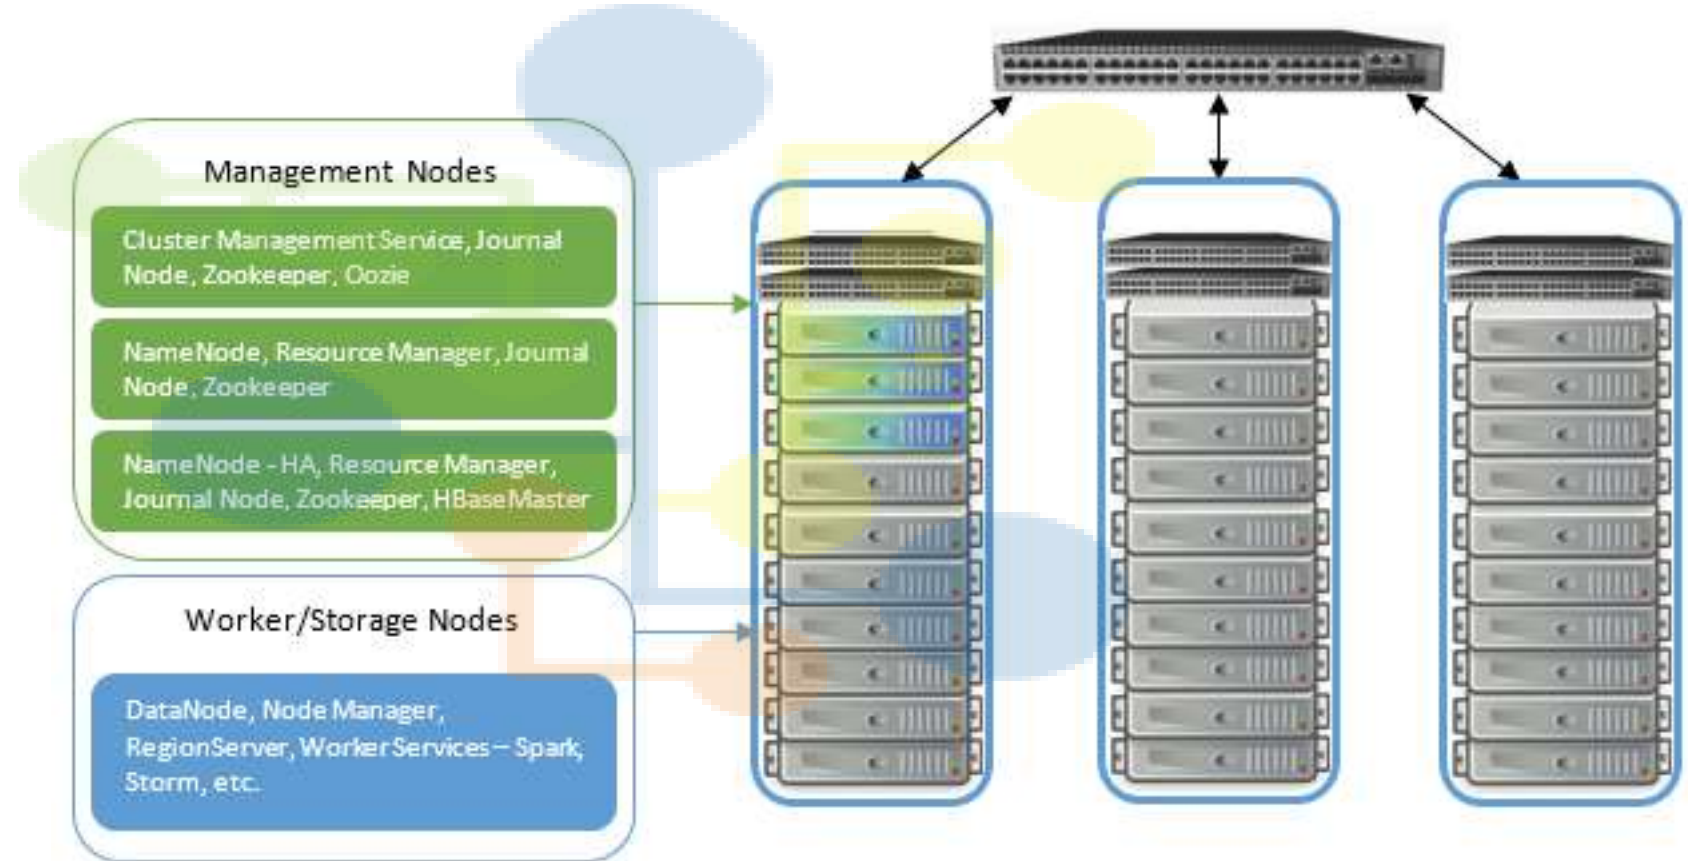
# Administração e Manutenção do Hadoop

A faint, stylized diagram in the background, consisting of a central vertical line with several horizontal branches. Each branch ends in a colored circle (blue, green, yellow, or orange), representing a network or data structure.



# Administração e Manutenção do Hadoop

## Cluster Hadoop





# Desafios na Administração e Manutenção de um Cluster Hadoop



# Administração e Manutenção do Hadoop

## Desafios na gestão do cluster Hadoop

Falta de gestão de configuração

Baixa alocação de recursos

Gargalos de rede

Falta de métricas de monitoramento





# Administração e Manutenção do Hadoop

## Desafios na gestão do cluster Hadoop

Medidas drásticas  
para resolver  
problemas  
simples

Pontos únicos de  
falha

Utilização dos  
valores default  
para os  
parâmetros

Falta de  
profissionais  
qualificados





# Administração e Manutenção do Hadoop








# **NameNode e Estrutura de Diretórios**

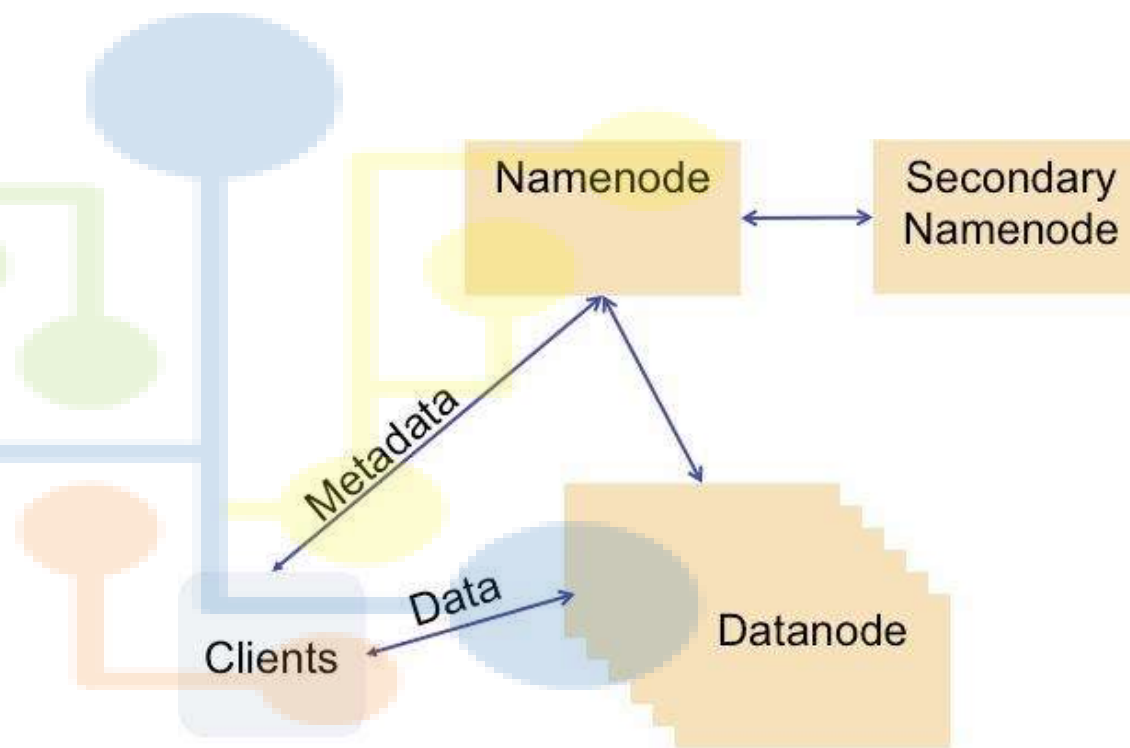




# Estrutura de Diretórios do NameNode




**NAMENODE**






# Estrutura de Diretórios do NameNode



**NAMENODE**





# Estrutura de Diretórios do NameNode

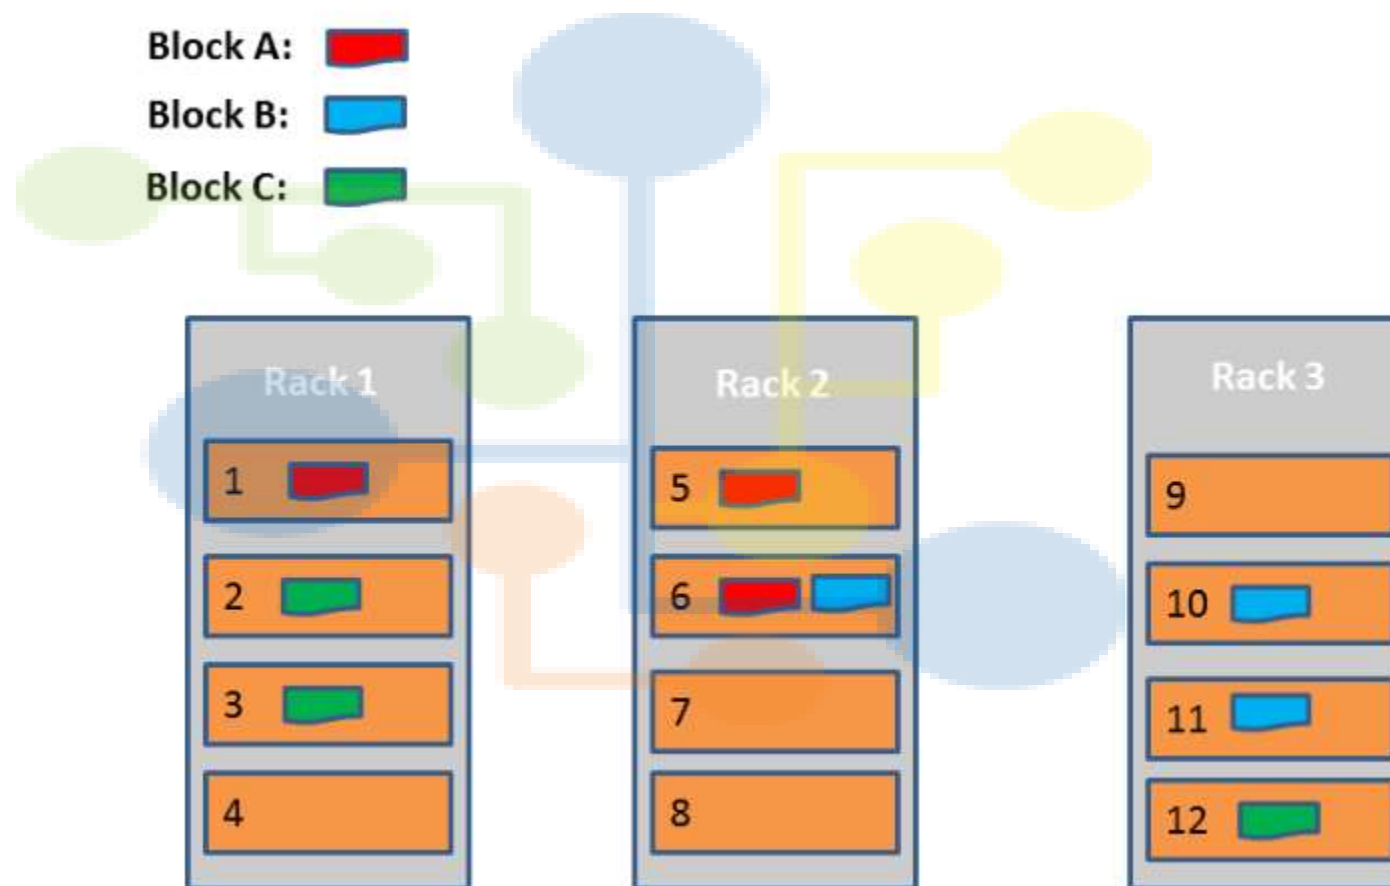
Com o passar do tempo, o número de arquivos edit-log pode se tornar grande demais, sendo necessária uma atualização do fs-image.

Essa é a função do SecondaryNameNode, que veremos mais adiante.



# Estrutura de Diretórios do NameNode

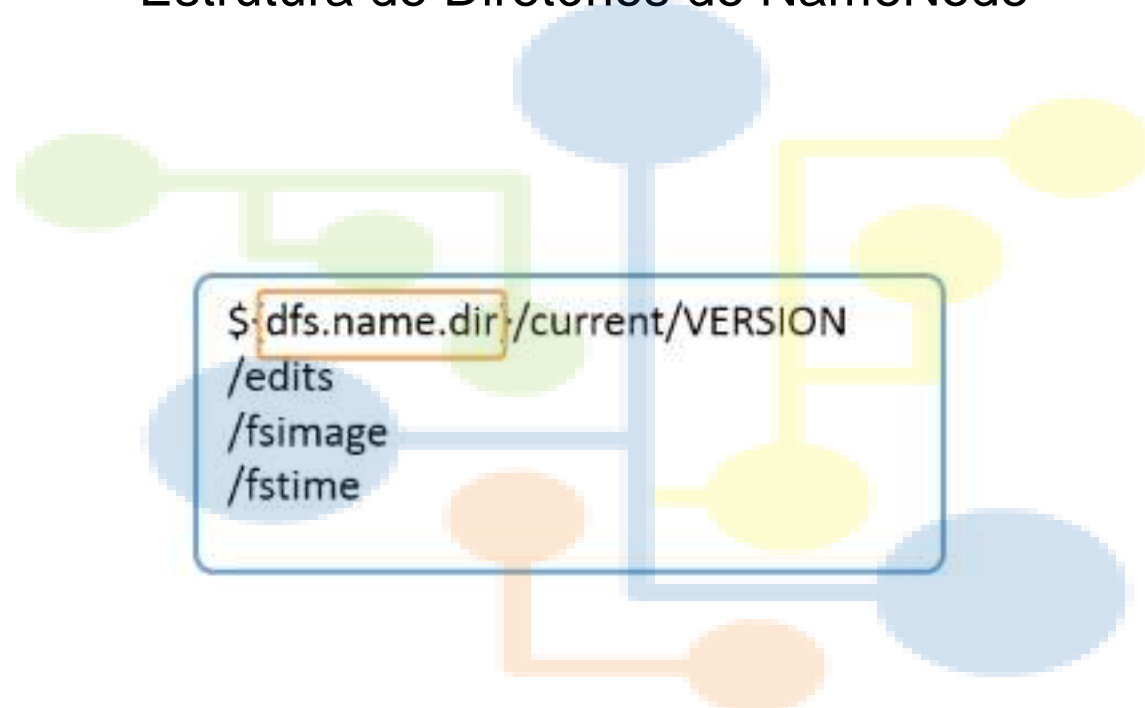
Rack Awareness





# Estrutura de Diretórios do NameNode

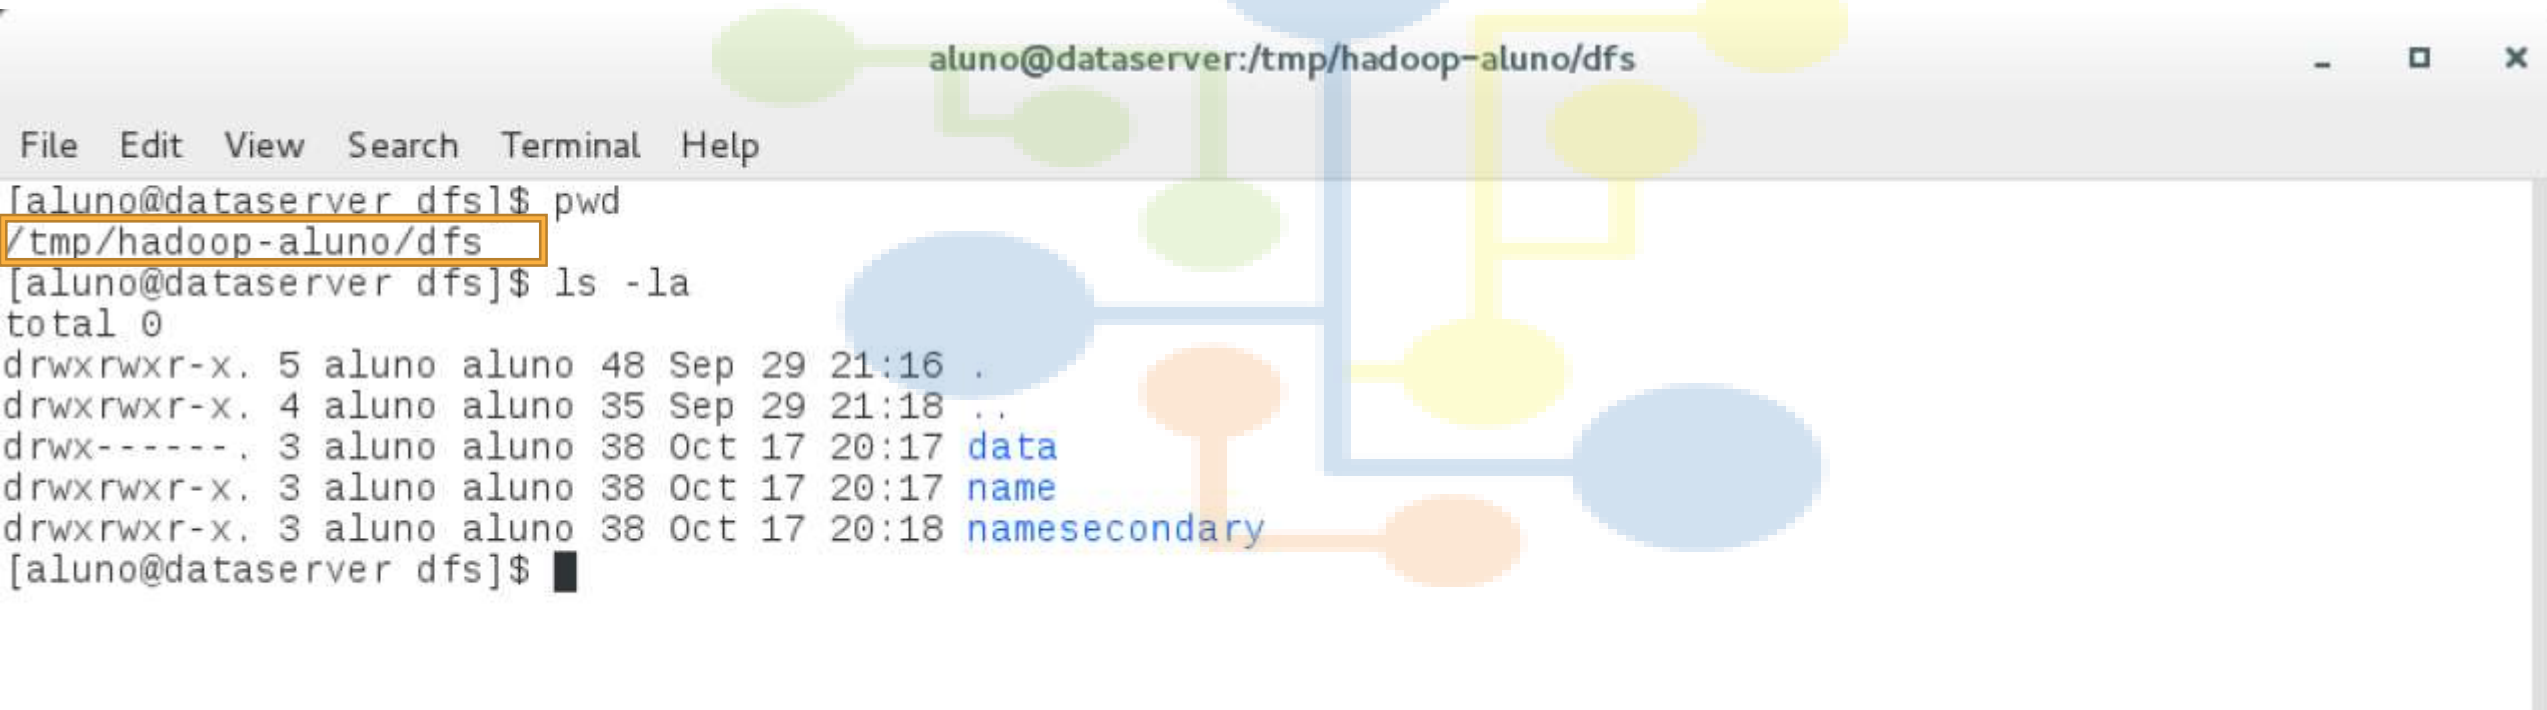
## Estrutura de Diretórios do NameNode





# Estrutura de Diretórios do NameNode

## Estrutura de Diretórios do NameNode



The image shows a terminal window with a menu bar (File, Edit, View, Search, Terminal, Help) and a title bar (aluno@dataserver: /tmp/hadoop-aluno/dfs). The terminal output shows the current directory and a listing of files in the /tmp/hadoop-aluno/dfs directory. The files are: ., .., data, name, and namesecondary. The file 'name' is highlighted in blue in the original image.

```
aluno@dataserver: /tmp/hadoop-aluno/dfs  
File Edit View Search Terminal Help  
[aluno@dataserver dfs]$ pwd  
/tmp/hadoop-aluno/dfs  
[aluno@dataserver dfs]$ ls -la  
total 0  
drwxrwxr-x. 5 aluno aluno 48 Sep 29 21:16 .  
drwxrwxr-x. 4 aluno aluno 35 Sep 29 21:18 ..  
drwx----- 3 aluno aluno 38 Oct 17 20:17 data  
drwxrwxr-x. 3 aluno aluno 38 Oct 17 20:17 name  
drwxrwxr-x. 3 aluno aluno 38 Oct 17 20:18 namesecondary  
[aluno@dataserver dfs]$
```



# Estrutura de Diretórios do NameNode

aluno@dataserver:/tmp/hadoop-aluno/dfs/name/current

File Edit View Search Terminal Help

```
[aluno@dataserver current]$ pwd
```

```
/tmp/hadoop-aluno/dfs/name/current
```

```
[aluno@dataserver current]$ ls -la
```

```
total 7244
```

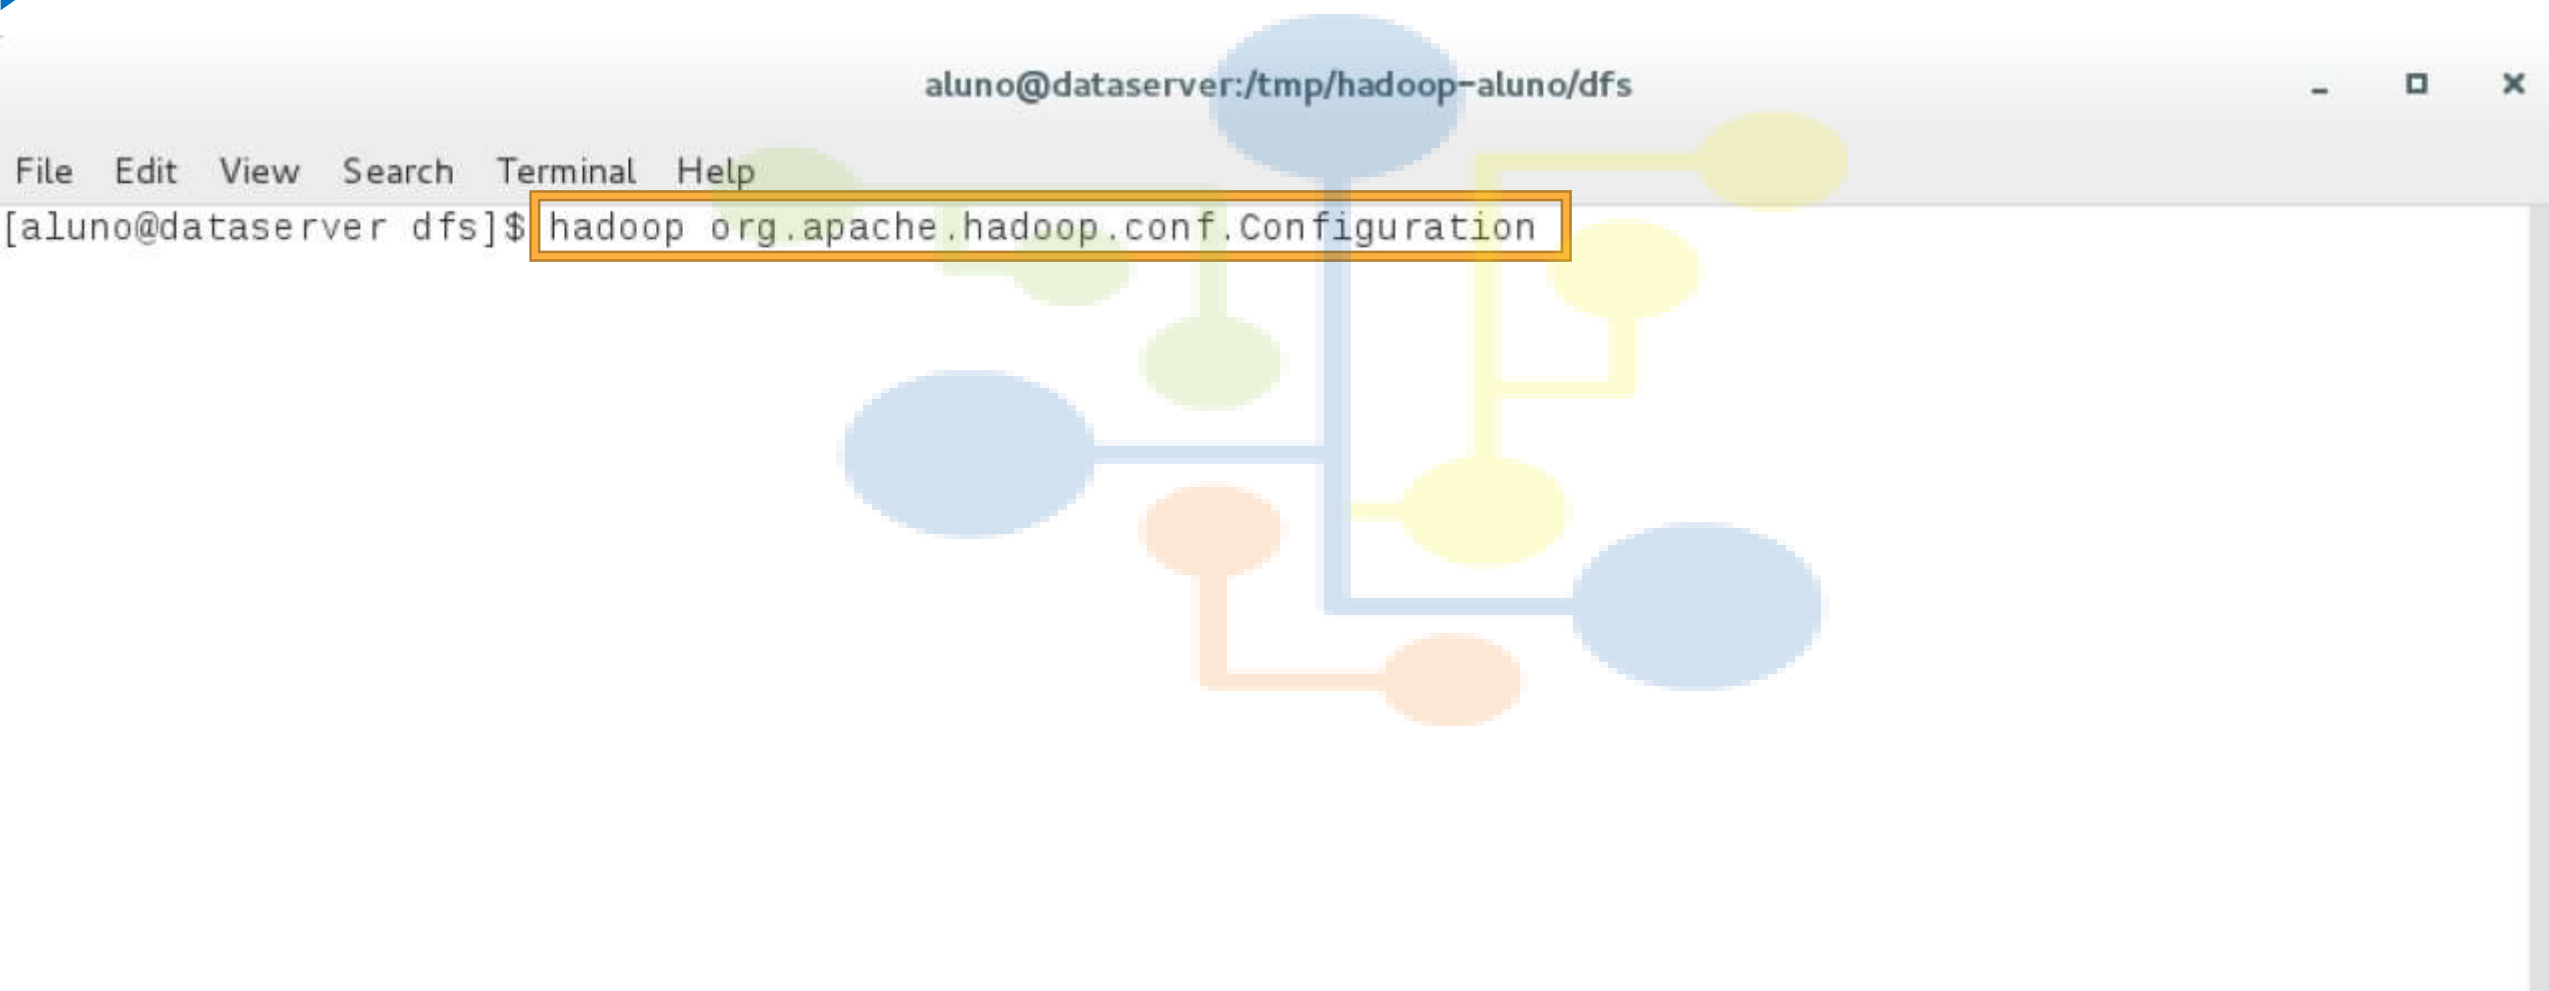
```
drwxrwxr-x. 2 aluno aluno 4096 Oct 17 20:28 .
drwxrwxr-x. 3 aluno aluno 38 Oct 17 20:17 ..
-rw-rw-r--. 1 aluno aluno 1048576 Sep 30 19:45 edits_000000000000000000120-000000000000000000120
-rw-rw-r--. 1 aluno aluno 1048576 Oct 16 18:30 edits_000000000000000000121-000000000000000000121
-rw-rw-r--. 1 aluno aluno 1048576 Oct 16 18:42 edits_000000000000000000122-000000000000000000122
-rw-rw-r--. 1 aluno aluno 1048576 Oct 16 18:48 edits_000000000000000000123-000000000000000000123
-rw-rw-r--. 1 aluno aluno 1048576 Oct 16 19:02 edits_000000000000000000124-000000000000000000124
-rw-rw-r--. 1 aluno aluno 42 Oct 16 20:06 edits_000000000000000000125-000000000000000000126
-rw-rw-r--. 1 aluno aluno 38394 Oct 16 21:06 edits_000000000000000000127-000000000000000000441
-rw-rw-r--. 1 aluno aluno 42 Oct 16 22:06 edits_000000000000000000442-000000000000000000443
-rw-rw-r--. 1 aluno aluno 1048576 Oct 16 22:06 edits_000000000000000000444-000000000000000000444
-rw-rw-r--. 1 aluno aluno 1048576 Oct 17 20:17 edits_inprogress_000000000000000000445
-rw-rw-r--. 1 aluno aluno 2587 Oct 16 22:06 fsimage_000000000000000000443
-rw-rw-r--. 1 aluno aluno 62 Oct 16 22:06 fsimage_000000000000000000443.md5
-rw-rw-r--. 1 aluno aluno 2587 Oct 17 20:17 fsimage_000000000000000000444
-rw-rw-r--. 1 aluno aluno 62 Oct 17 20:17 fsimage_000000000000000000444.md5
-rw-rw-r--. 1 aluno aluno 4 Oct 17 20:17 seen_txid
-rw-rw-r--. 1 aluno aluno 201 Oct 17 20:17 VERSION
```

```
[aluno@dataserver current]$
```





# Estrutura de Diretórios do NameNode





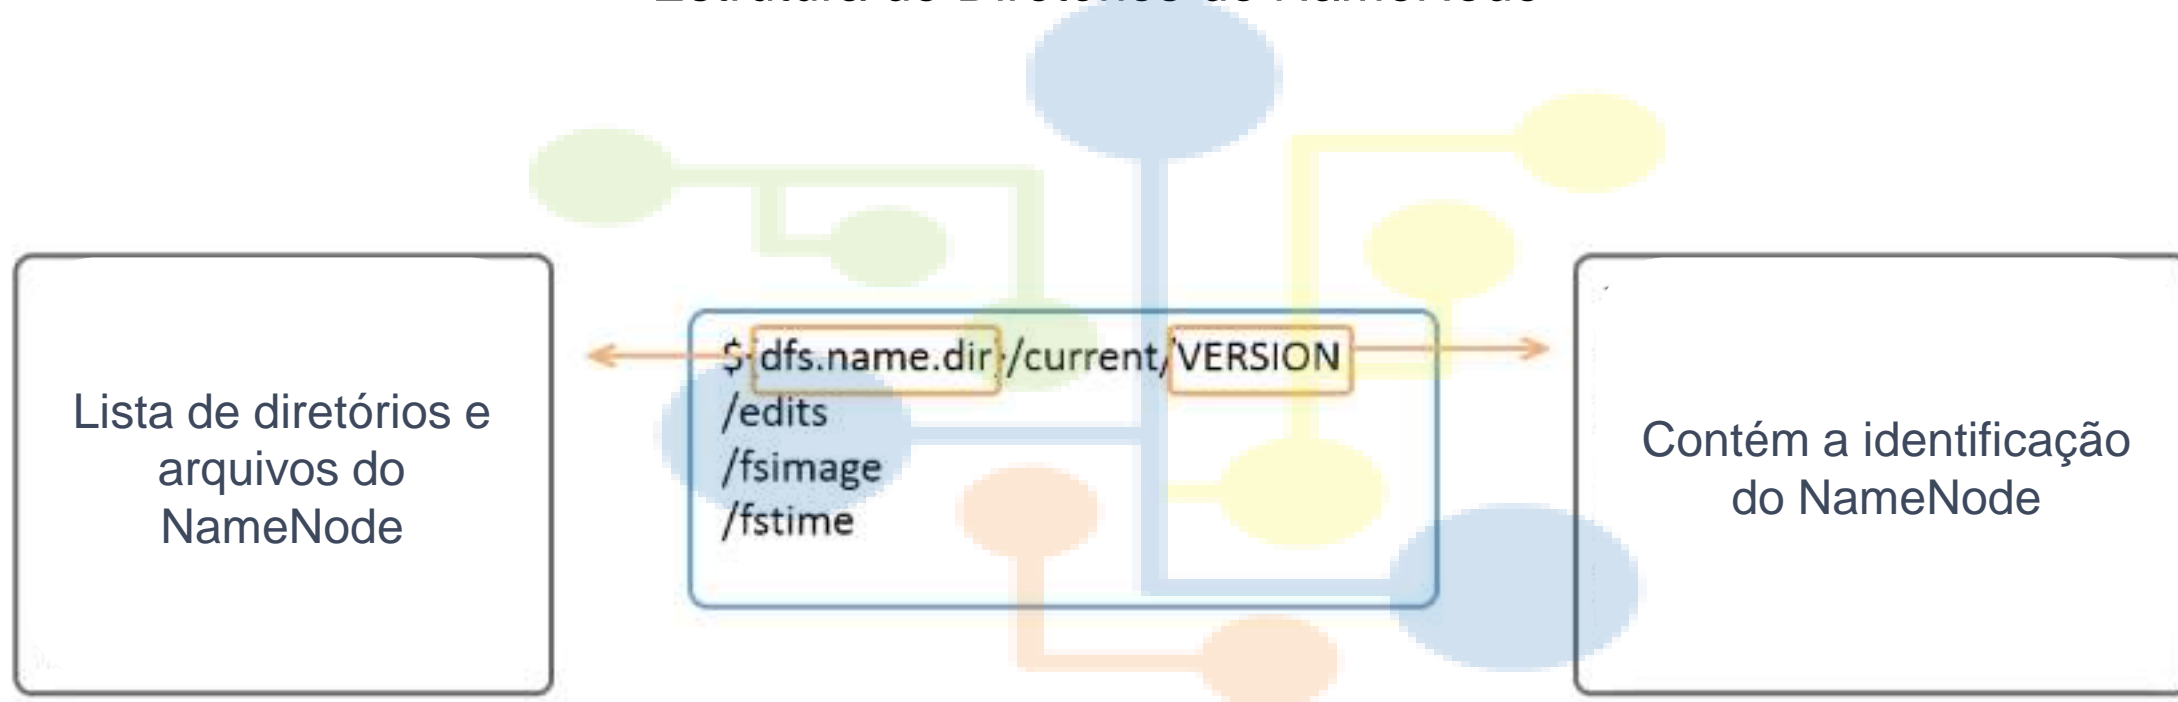
# Estrutura de Diretórios do NameNode

```
aluno@dataserver:~  
File Edit View Search Terminal Help  
<property><name>ipc.client.connection.maxidletime</name><value>10000</value><source>core-default.xml</source></property>  
<property><name>ipc.client.connect.timeout</name><value>20000</value><source>core-default.xml</source></property>  
<property><name>hadoop.security.uid.cache.secs</name><value>14400</value><source>core-default.xml</source></property>  
<property><name>ipc.client.ping</name><value>true</value><source>core-default.xml</source></property>  
<property><name>ipc.client.kill.max</name><value>10</value><source>core-default.xml</source></property>  
<property><name>ipc.client.connect.max.retries</name><value>10</value><source>core-default.xml</source></property>  
<property><name>ipc.ping.interval</name><value>60000</value><source>core-default.xml</source></property>  
<property><name>io.seqfile.local.dir</name><value>${hadoop.tmp.dir}/io/local</value><source>core-default.xml</source></property>  
<property><name>hadoop.security.crypto.buffer.size</name><value>8192</value><source>core-default.xml</source></property>  
<property><name>io.native.lib.available</name><value>true</value><source>core-default.xml</source></property>  
<property><name>io.file.buffer.size</name><value>4096</value><source>core-default.xml</source></property>  
<property><name>io.serializations</name><value>org.apache.hadoop.io.serializer.WritableSerialization,org.apache.hadoop.io.serializer.avro.AvroSpe  
cificSerialization,org.apache.hadoop.io.serializer.avro.AvroReflectSerialization</value><source>core-default.xml</source></property>  
<property><name>tfile.fs.input.buffer.size</name><value>262144</value><source>core-default.xml</source></property>  
<property><name>hadoop.registry.zk.session.timeout.ms</name><value>60000</value><source>core-default.xml</source></property>  
<property><name>hadoop.security.group.mapping.ldap.ssl</name><value>false</value><source>core-default.xml</source></property>  
<property><name>fs.df.interval</name><value>60000</value><source>core-default.xml</source></property>  
<property><name>hadoop.http.authentication.kerberos.keytab</name><value>${user.home}/hadoop.keytab</value><source>core-default.xml</source></prop  
erty>  
<property><name>s3native.client.write.packet.size</name><value>65536</value><source>core-default.xml</source></property>  
<property><name>s3native.replication</name><value>3</value><source>core-default.xml</source></property>  
<property><name>hadoop.http.cross-origin.allowed-headers</name><value>X-Requested-With,Content-Type,Accept,Origin</value><source>core-default.xml  
</source></property>  
<property><name>tfile.io.chunk.size</name><value>1048576</value><source>core-default.xml</source></property>  
<property><name>hadoop.ssl.hostname.verifier</name><value>DEFAULT</value><source>core-default.xml</source></property>  
[aluno@dataserver ~]$
```



# Estrutura de Diretórios do NameNode

## Estrutura de Diretórios do NameNode





# Estrutura de Diretórios do NameNode

Poucos arquivos grandes consomem menos memória



# A Importância do Secondary NameNode



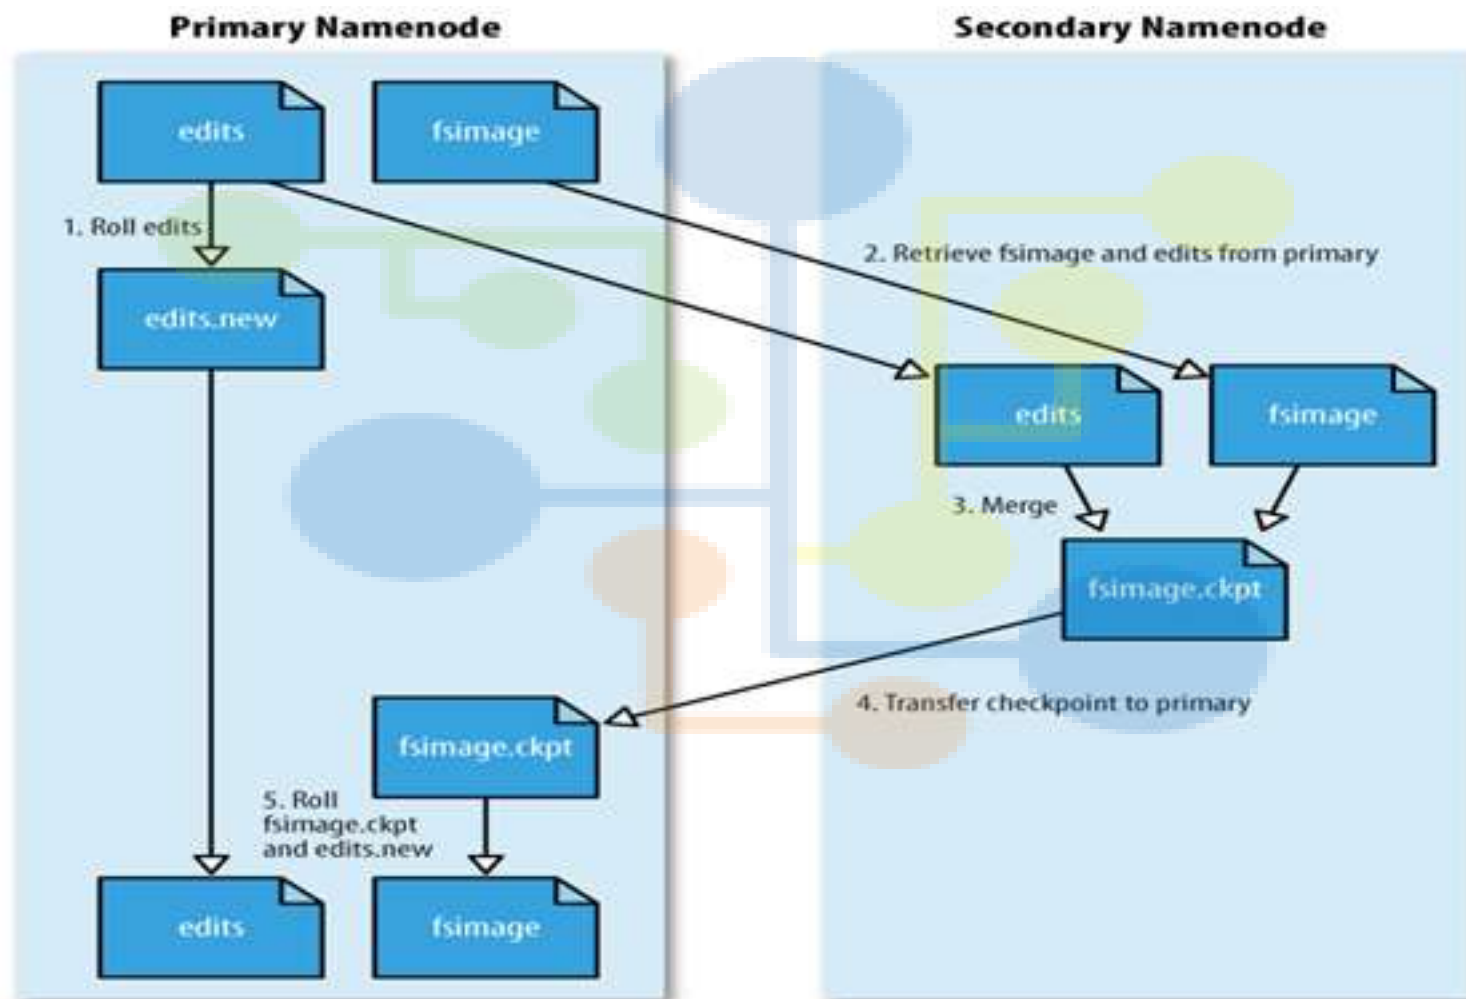


# Secondary NameNode

O Secondary NameNode é o processo responsável por sincronizar os arquivos edit logs com a imagem do fsimage, para gerar um novo fsimage mais atualizado.



# Secondary NameNode





# Secondary NameNode

O principal objetivo do Secondary NameNode é ajudar a reconstruir o NameNode no caso desse vir a falhar!





# DataNodes e Estrutura de Diretórios





# Estrutura de Diretórios do DataNode

Os DataNodes não precisam ser formatados (como o NameNode), uma vez que eles criam seus diretórios no storage automaticamente na inicialização.



# Estrutura de Diretórios do DataNode

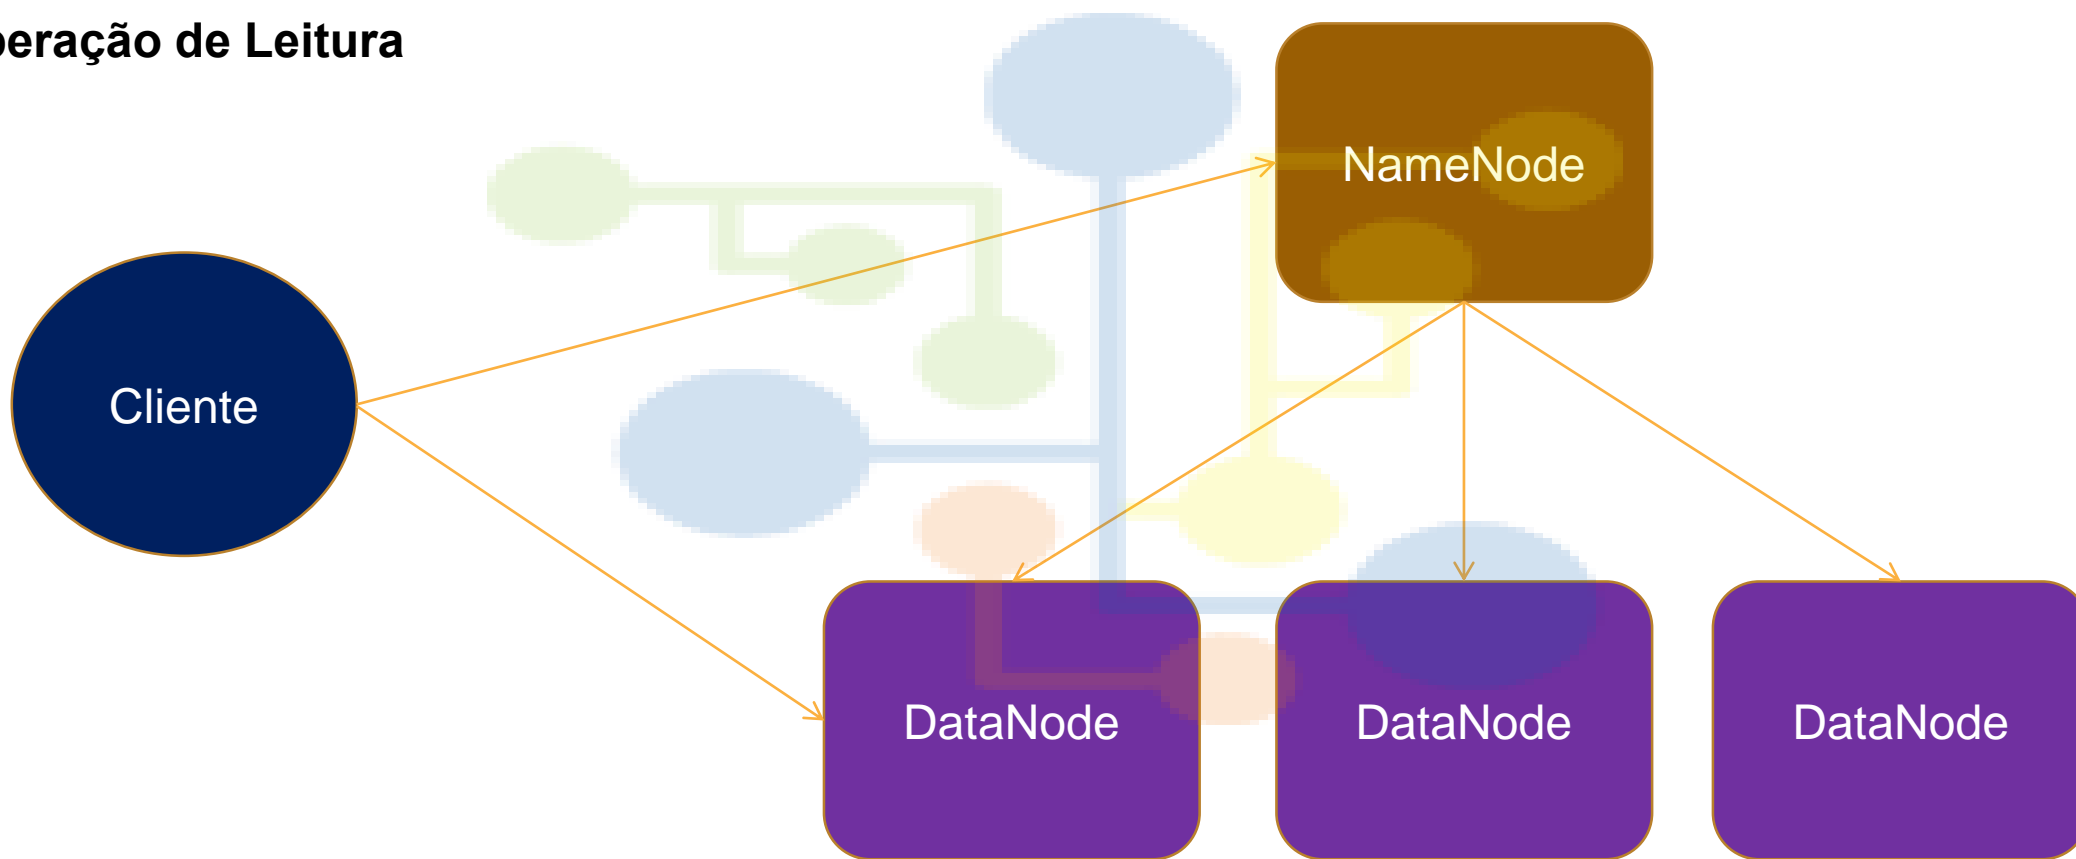
A estrutura do DataNode é muito similar a do NameNode, com um arquivo VERSION com informações sobre o servidor e os arquivos binários de operação do serviço DataNode. Esse diretório é definido pelo parâmetro `dfs.data.node.dir`, nos arquivos de configuração do Hadoop.

```
hadoop@dataserver:/opt/hadoop/dfs/data/current
File Edit View Search Terminal Help
(base) [hadoop@dataserver ~]$ cd /opt/hadoop/dfs/data/
(base) [hadoop@dataserver data]$ ls -la
total 0
drwx----- . 3 hadoop hadoop 21 Oct 20 13:06 .
drwxrwxr-x. 5 hadoop hadoop 61 Oct 20 12:51 ..
drwxrwxr-x. 3 hadoop hadoop 66 Oct 20 12:01 current
(base) [hadoop@dataserver data]$ cd current/
(base) [hadoop@dataserver current]$ ls
BP-2051156013-127.0.0.1-1563253115551 VERSION
(base) [hadoop@dataserver current]$ ls -la
total 4
drwxrwxr-x. 3 hadoop hadoop 66 Oct 20 12:01 .
drwx----- . 3 hadoop hadoop 21 Oct 20 13:06 ..
drwx----- . 4 hadoop hadoop 54 Oct 20 12:52 BP-2051156013-127.0.0.1-1563253115551
-rw-rw-r-- . 1 hadoop hadoop 229 Oct 20 12:52 VERSION
(base) [hadoop@dataserver current]$
```



# Estrutura de Diretórios do DataNode

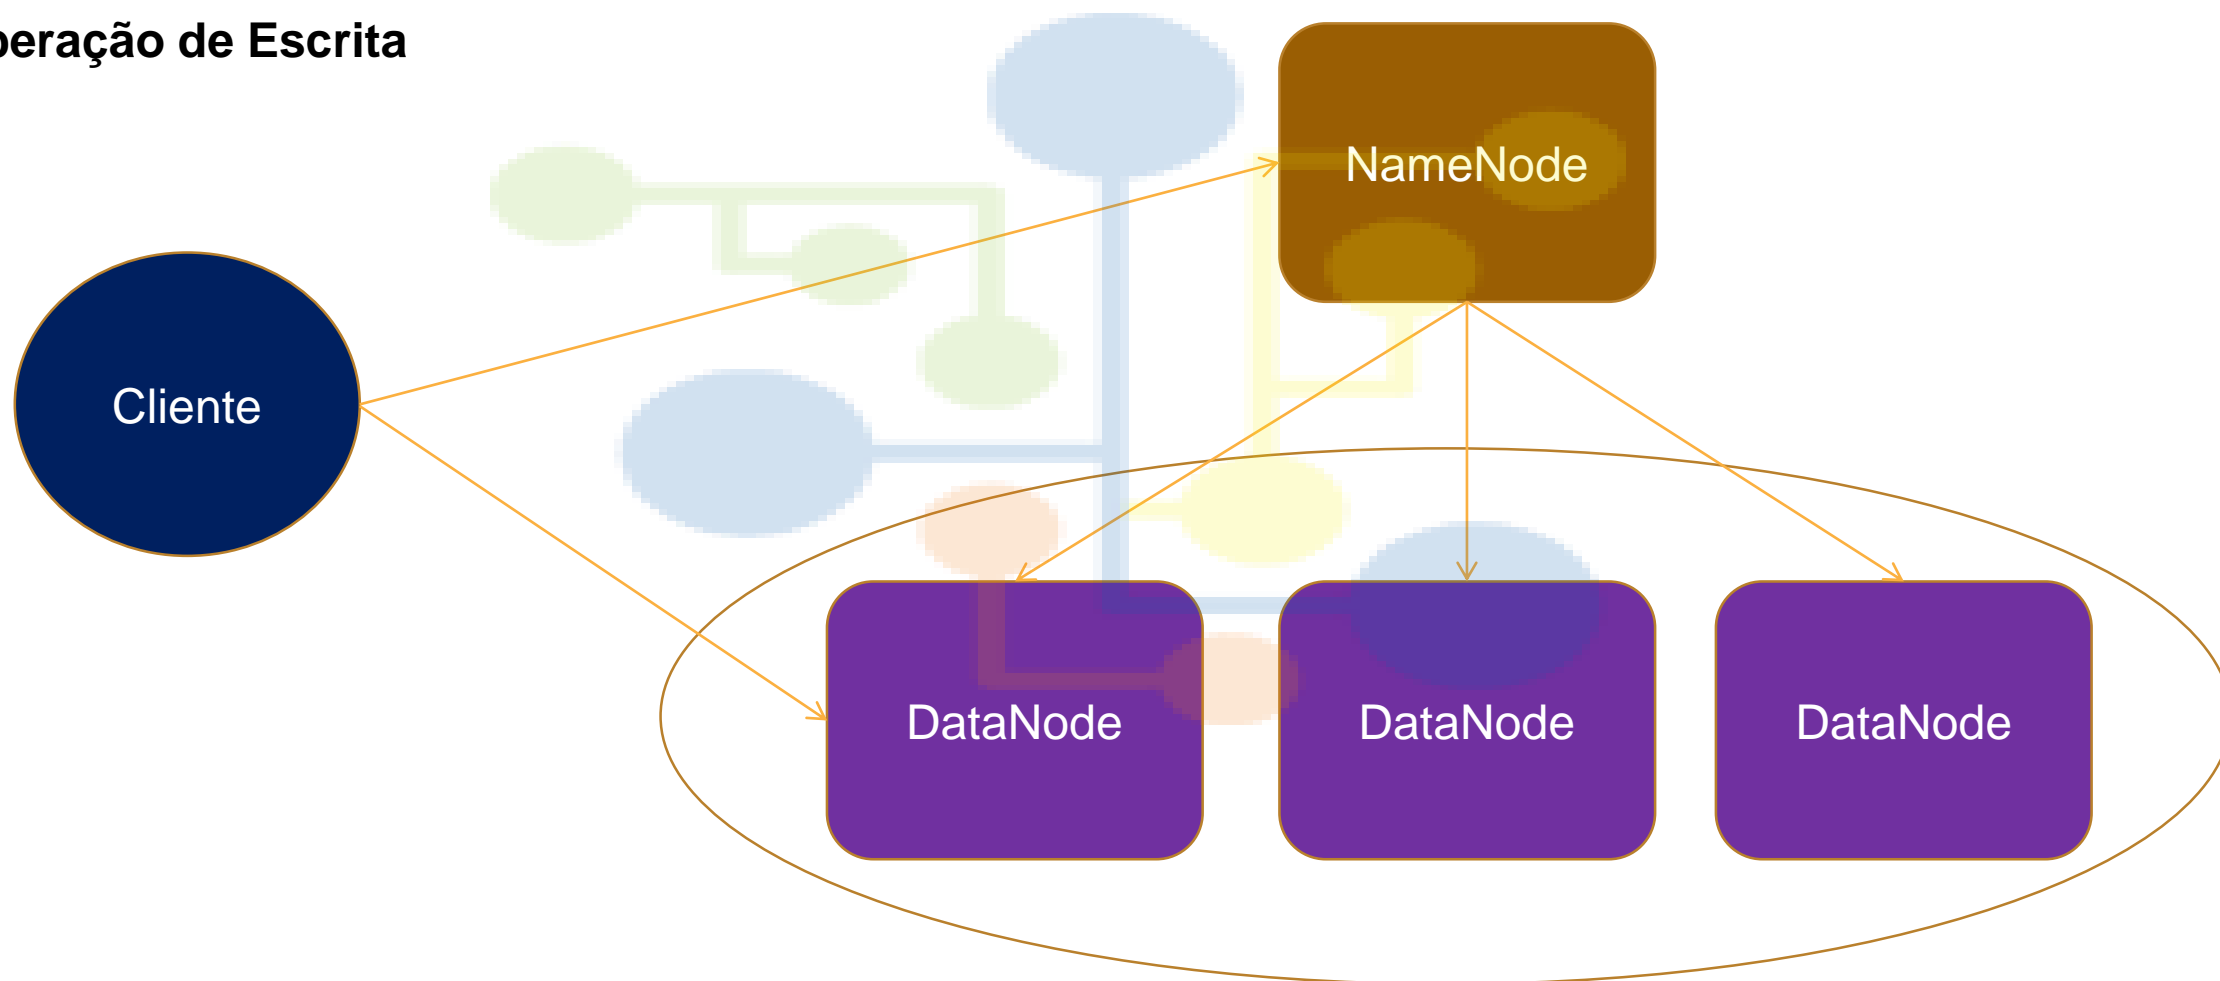
## Operação de Leitura





# Estrutura de Diretórios do DataNode

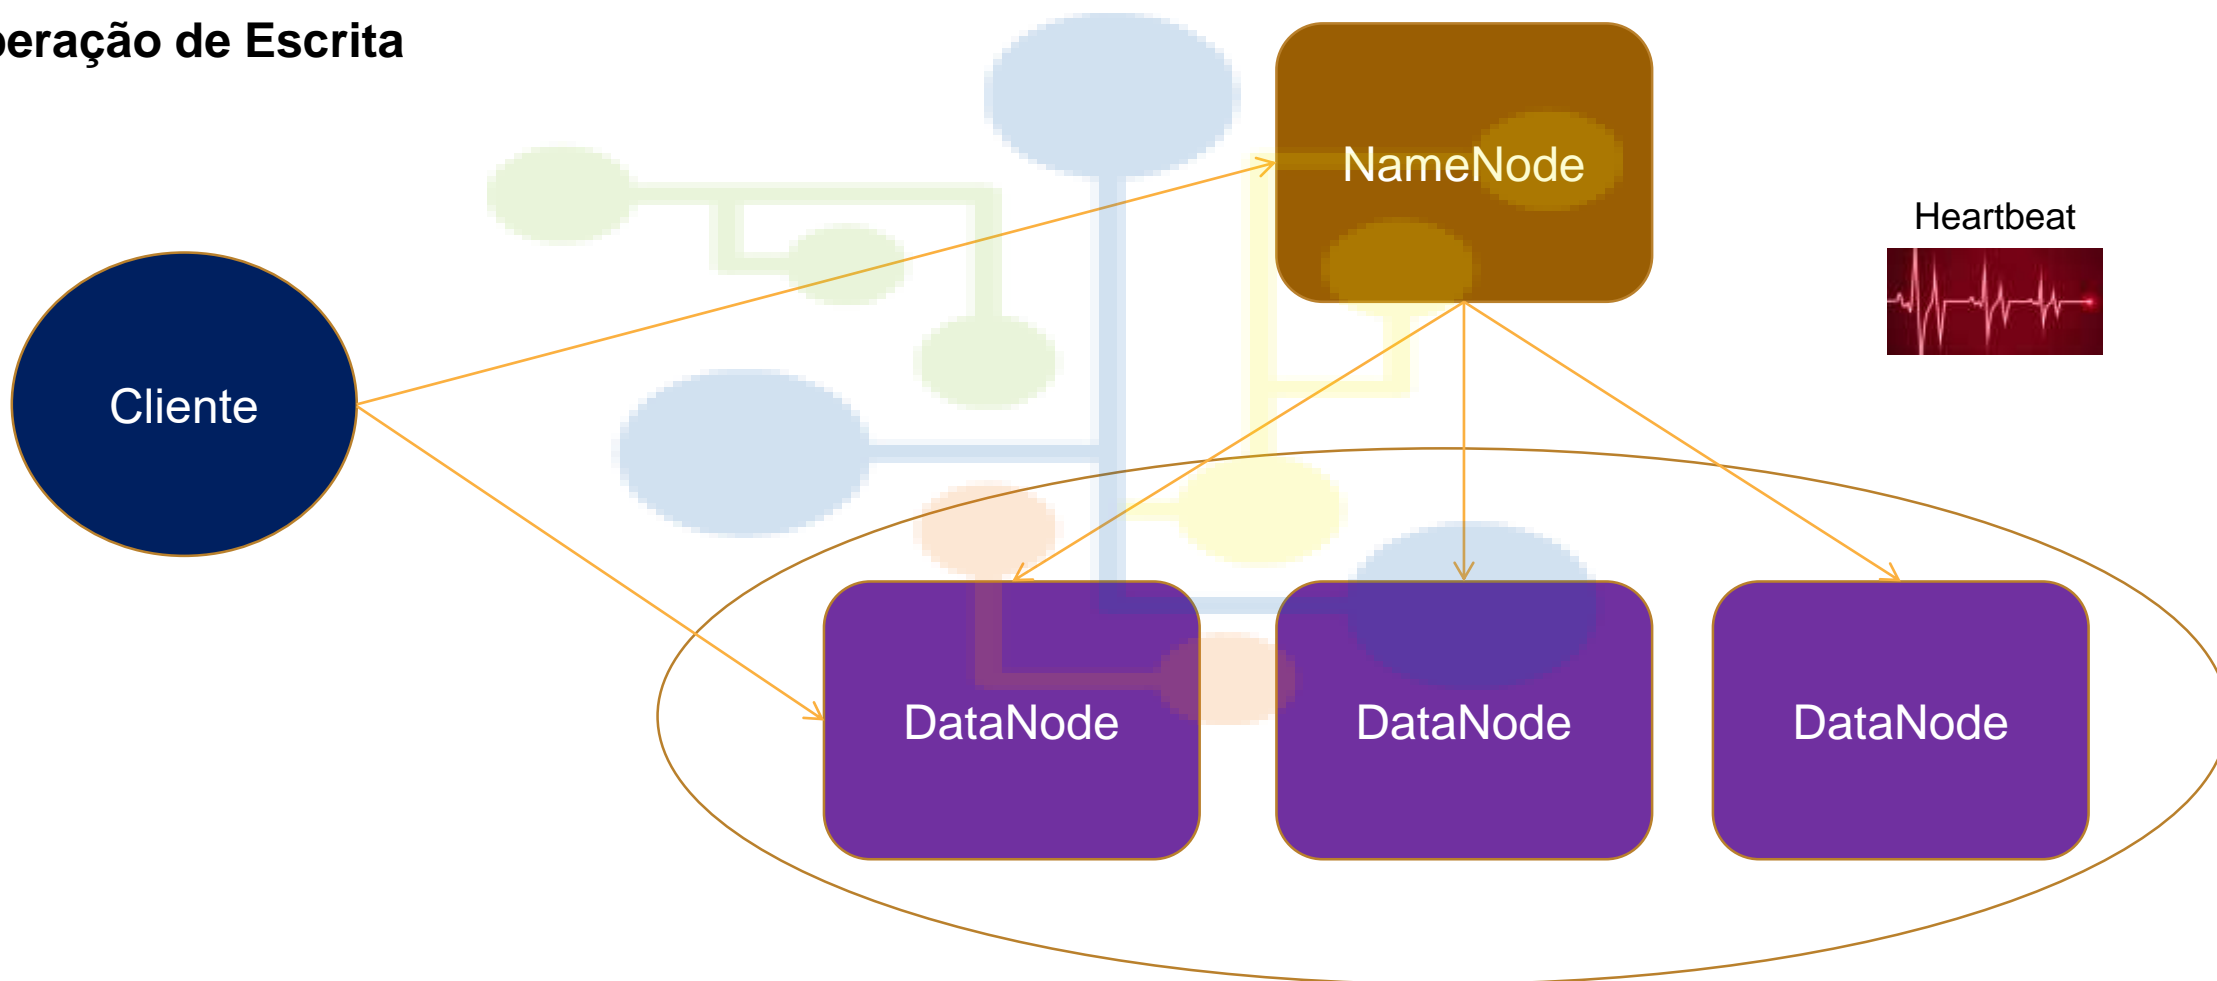
## Operação de Escrita





# Estrutura de Diretórios do DataNode

## Operação de Escrita






# Estrutura de Diretórios do DataNode

Tamanho padrão do bloco = 67108864 (64Mb)  
(versão anteriores)

Tamanho padrão do bloco = 134217728 (128Mb)  
(versão atuais)





# Estrutura de Diretórios do DataNode


Não se usa RAID de discos para fazer cópias de  
seguranças dos blocos.







# Metadados do Sistema de Arquivos





# Metadados do Sistema de Arquivos

Metadados → Informações gerais sobre o cluster e sobre os dados

Dados → Big Data



# Metadados do Sistema de Arquivos

**ATENÇÃO:** Não tente modificar diretórios ou arquivos de metadados. Modificações podem causar interrupção do HDFS ou até mesmo a perda de dados de forma permanente.

O Backup dos metadados é uma tarefa crítica em um cluster Hadoop.



# Metadados do Sistema de Arquivos

fsimage	Edit log
Representa uma imagem point-in-time dos metadados do file system	Contém uma série de arquivos, chamados segmentos
O arquivo é sequencial	Os segmentos representam todas as modificações feitas desde a data de criação do fsimage
Pode ser usado para obter o estado mais recente do file system quando o NameNode tiver problemas	Garante que nenhuma operação é perdida devido a uma falha do servidor

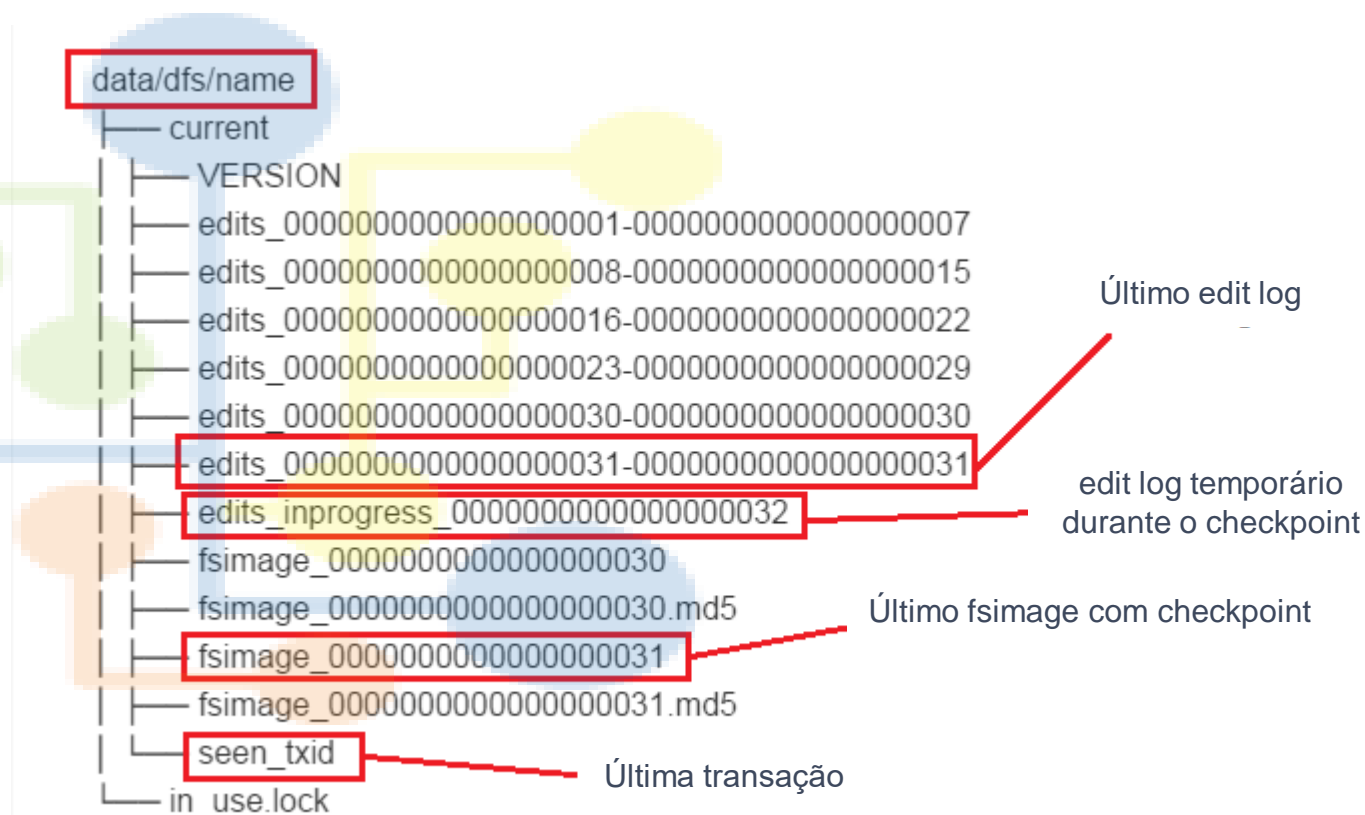
O fsimage não possui qualquer informação sobre os dados armazenados nos DataNodes.



# Metadados do Sistema de Arquivos

## NameNode

- VERSION
  - Layoutversion
  - namespaceID/clusterID/blockpoolIDstorageType
  - cTime
  - edits\_start transaction ID-end transaction ID
  - edits\_inprogress\_\_start transaction ID
  - fsimage\_end transaction ID
  - seen\_txid
- in\_use.lock



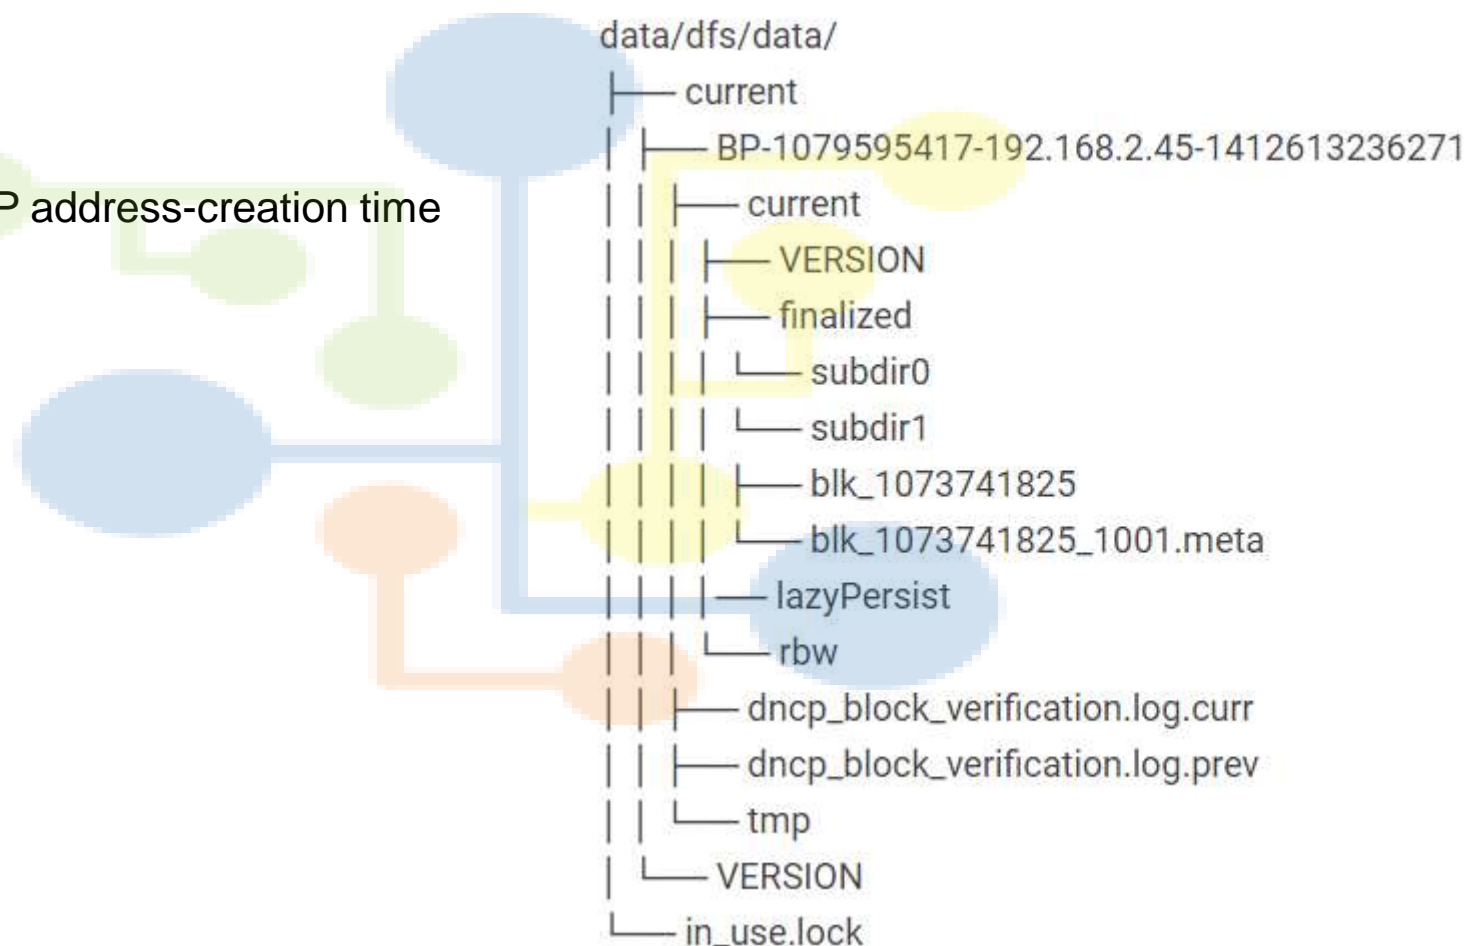
Parâmetro **`dfs.namenode.name.dir`** em `hdfs-site.xml`



# Metadados do Sistema de Arquivos

## DataNode

- BP-random integer-NameNode-IP address-creation time
- VERSION
  - storageType
  - blockpoolID
  - finalized/rbw
  - lazyPersist
  - dncp\_block\_verification.log
- in\_use.lock





# Metadados do Sistema de Arquivos

## Parâmetros de Configuração

Lista de Parâmetros para configuração dos diretórios do NameNode e DataNode	
dfs.namenode.name.dir	
dfs.namenode.edits.dir	
dfs.namenode.checkpoint.period	
dfs.namenode.checkpoint.txns	
dfs.namenode.checkpoint.check.period	
dfs.namenode.num.checkpoints.retained	
dfs.namenode.num.extra.edits.retained	
dfs.namenode.edit.log.autoroll.multiplier.threshold	
dfs.namenode.edit.log.autoroll.check.interval.ms	
dfs.datanode.data.dir	



# Metadados do Sistema de Arquivos

## Comandos de Configuração

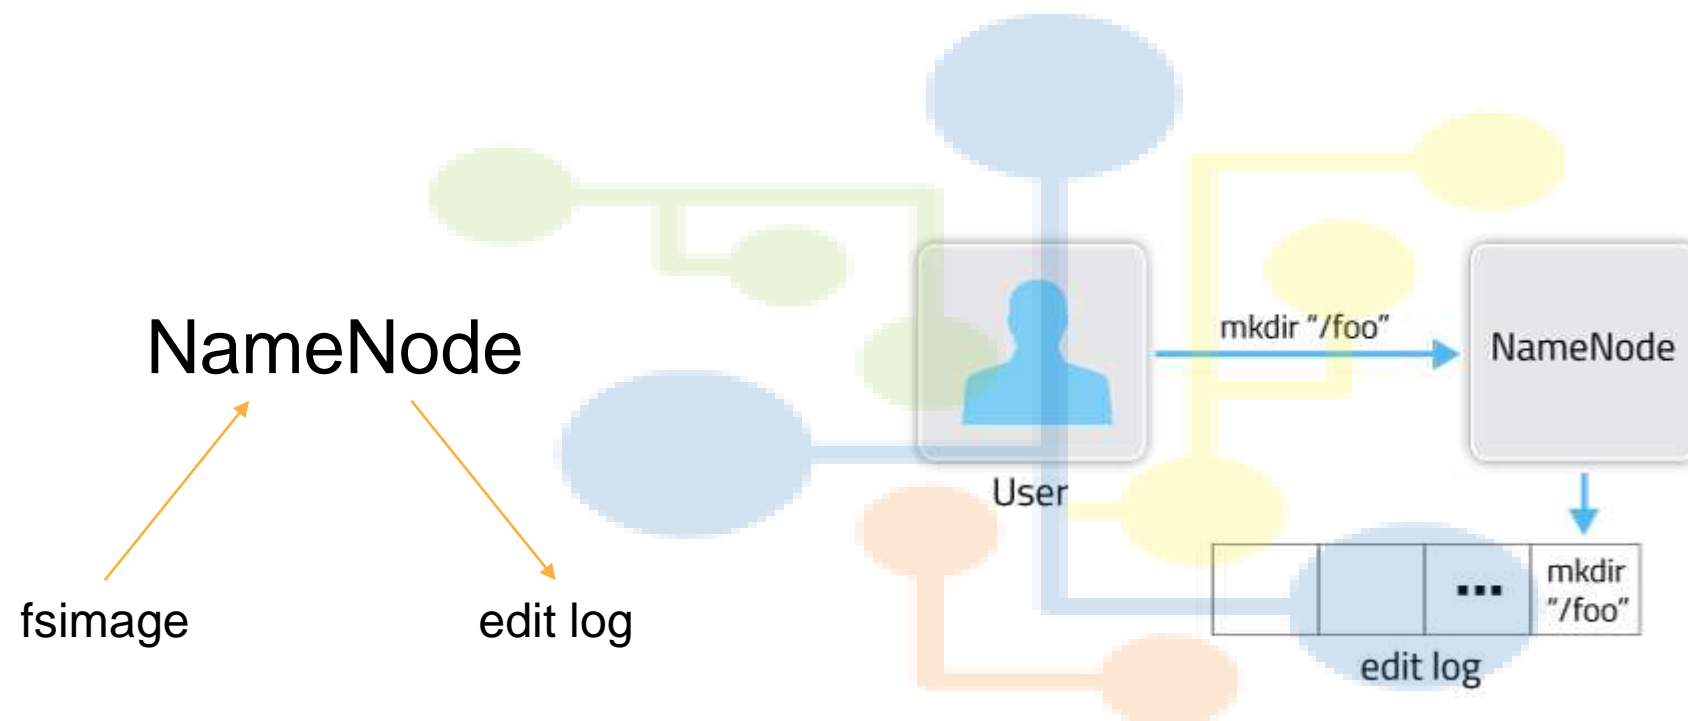
Comando	Descrição
<b>hdfs namenode</b>	Inicializa o NameNode
<b>hdfs dfsadmin -safemode enter</b> <b>hdfs dfsadmin -saveNamespace</b>	Coloca o NameNode em modo de segurança e realiza um checkpoint
<b>hdfs dfsadmin -rollEdits</b>	Passa de um edit log para outro
<b>hdfs dfsadmin -fetchImage</b>	Obtém a última versão do fsimage (o que pode ser usado para criar um NameNode backup)





# Procedimento de Checkpoint

A faint, stylized diagram in the background, consisting of a central vertical blue line with several horizontal and diagonal branches. The branches end in circles of various colors: blue, green, yellow, and orange. The diagram is centered behind the title text.

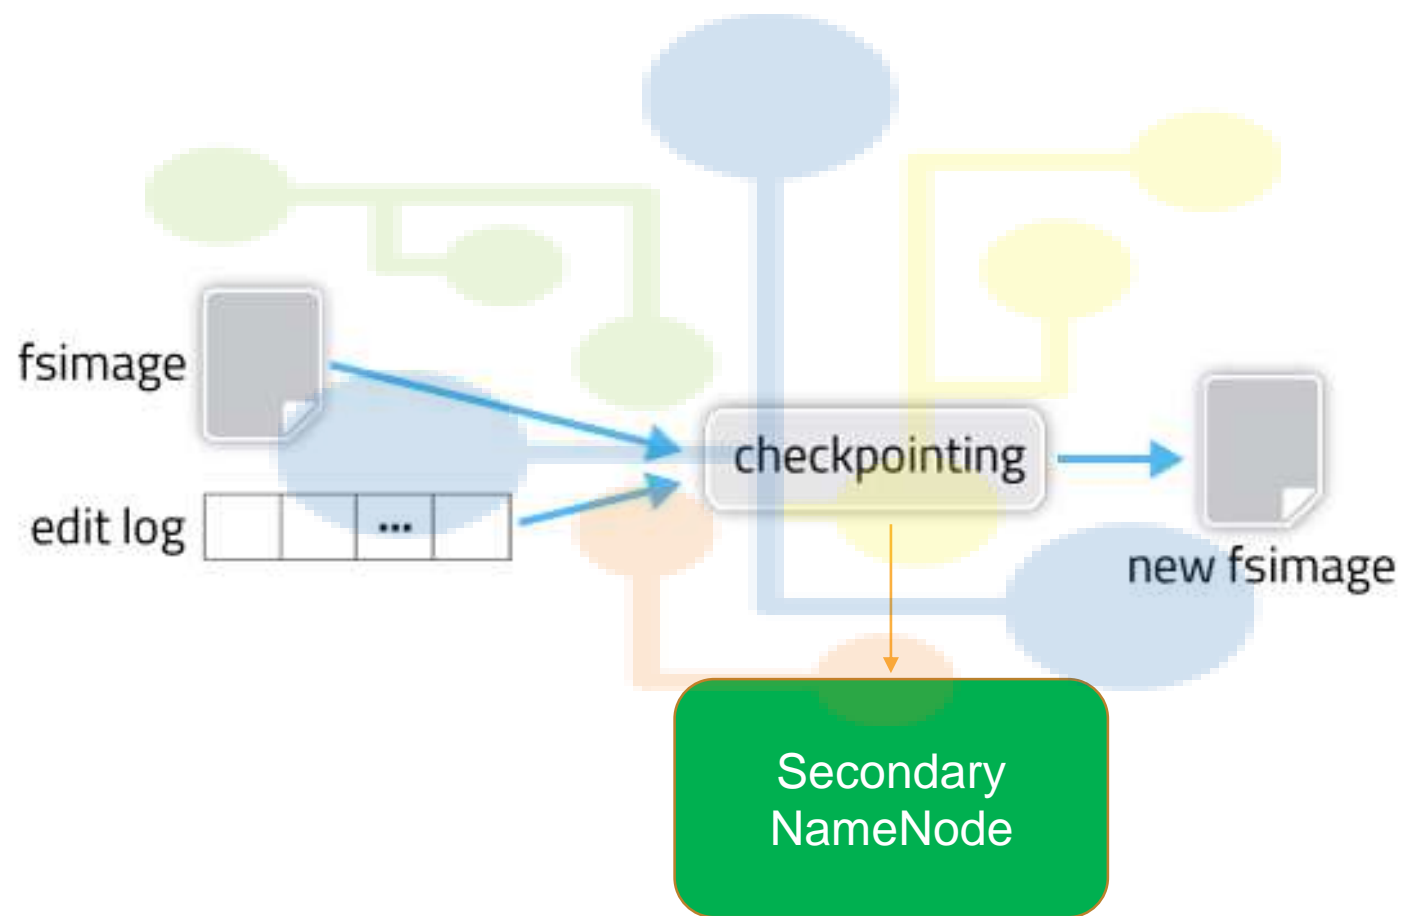


# Checkpoint




Data Science  
Academy

Data Science Academy marcelo\_eidi12@hotmail.com 5d5c42d55e4cde68f38b457d



Checkpoint é o processo pelo qual fsimage e edit log são combinados em um novo fsimage



O processo de checkpoint é controlado por 2 parâmetros

<b>dfs.namenode.checkpoint.period</b>	<b>dfs.namenode.checkpoint.txns</b>
O valor default é 1 hora, para garantir o próximo refresh entre 2 checkpoints consecutivos.	O valor default é 1 milhão e esta é a regra para definir o número de transações até o próximo checkpoint.

A faint, stylized diagram in the background of the slide, consisting of several colored circles (blue, green, yellow, orange) connected by lines, suggesting a network or data flow.

Compreender como funciona o checkpoint no HDFS pode fazer a diferença para ter um cluster eficiente.

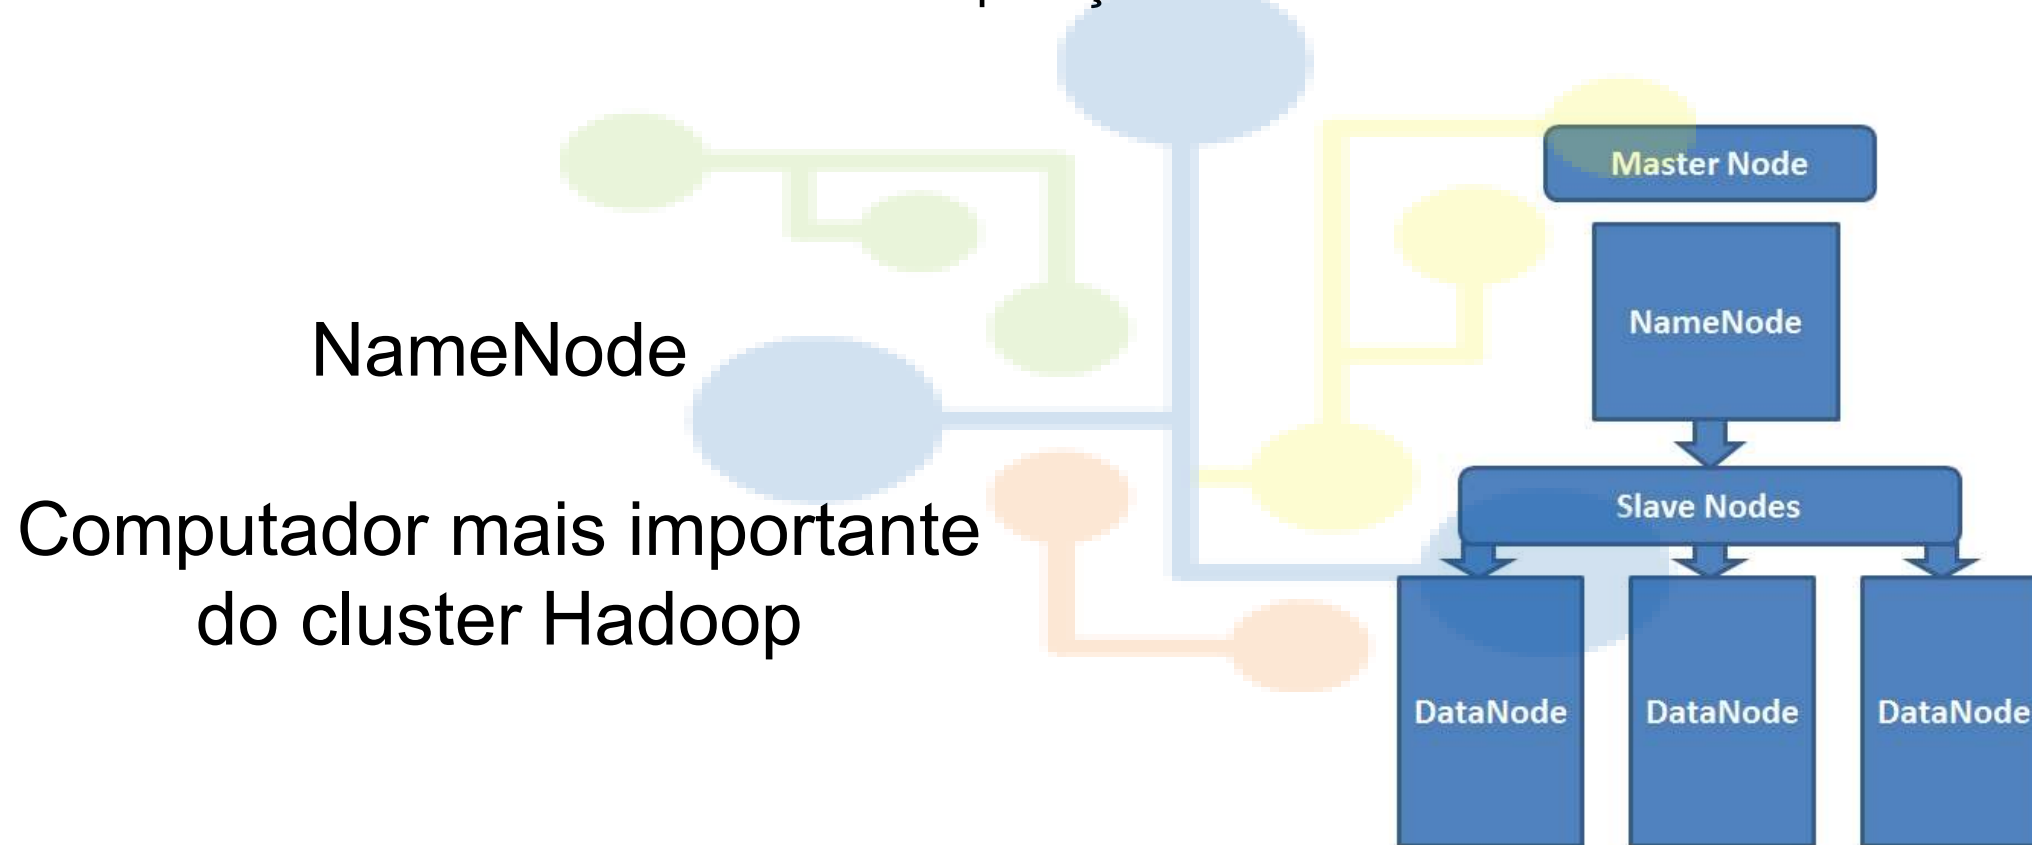


# Procedimento de Recuperação à Falha do NameNode



# Recuperação a Falhas

## Processo de Recuperação à Falha do NameNode

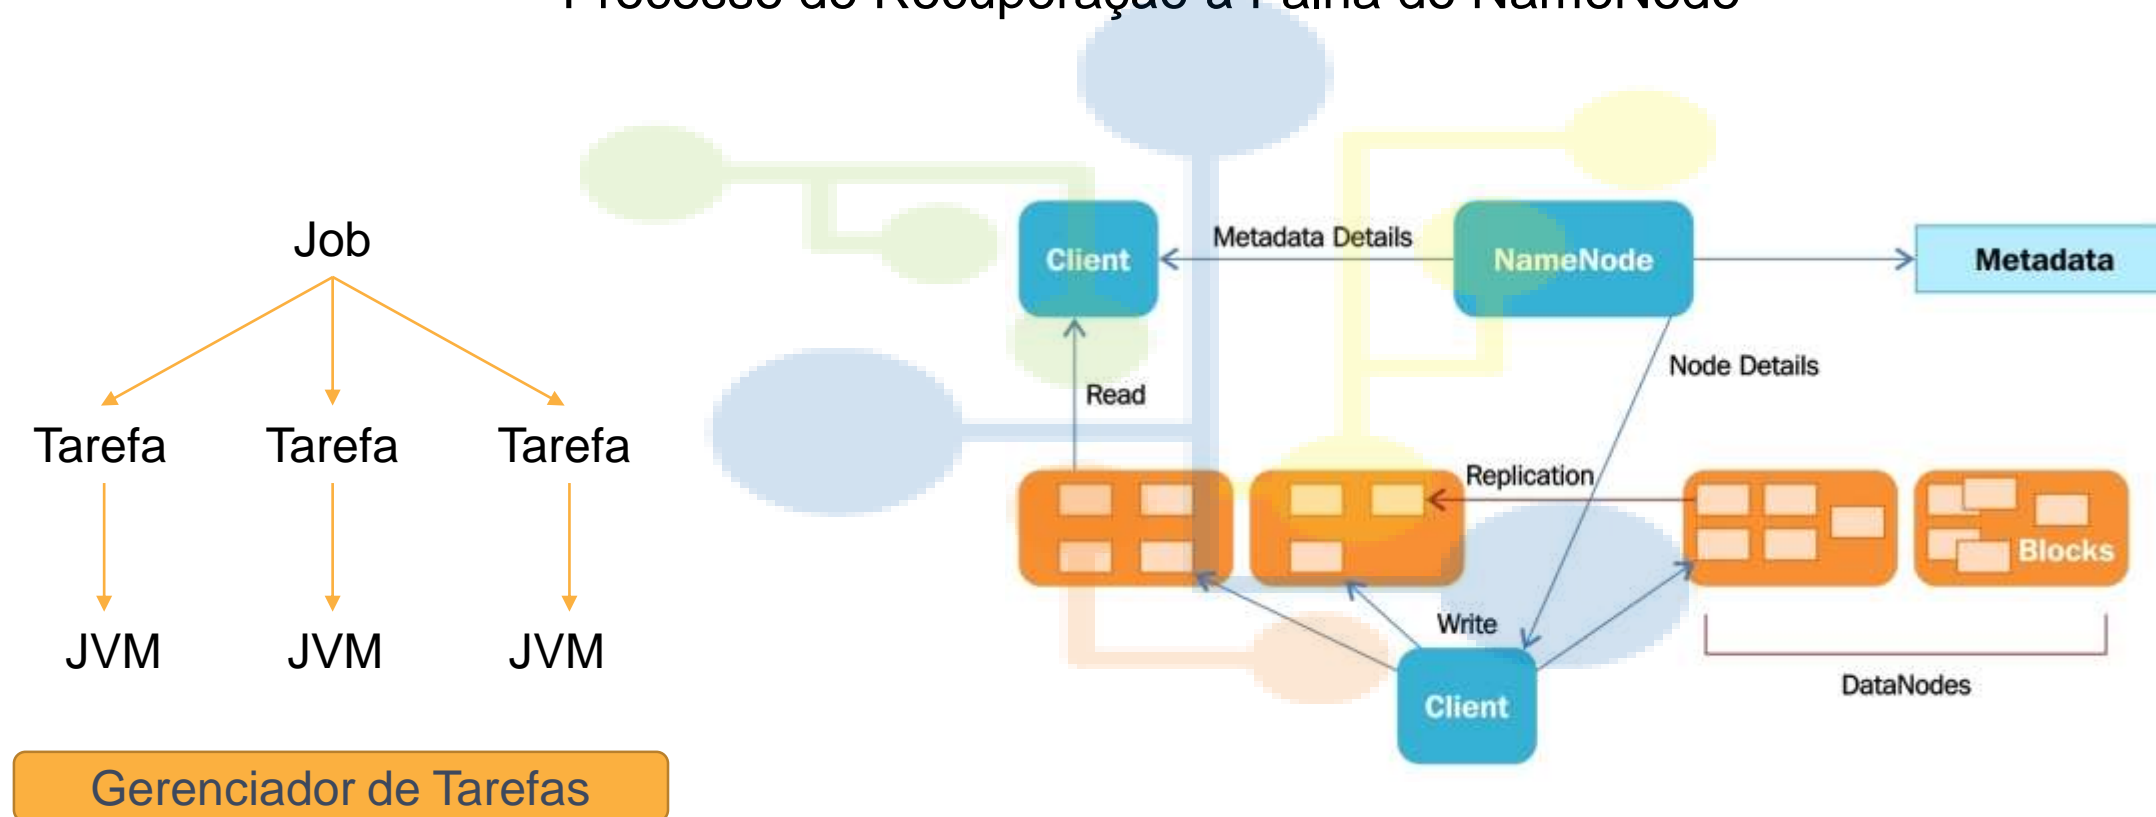






# Recuperação a Falhas

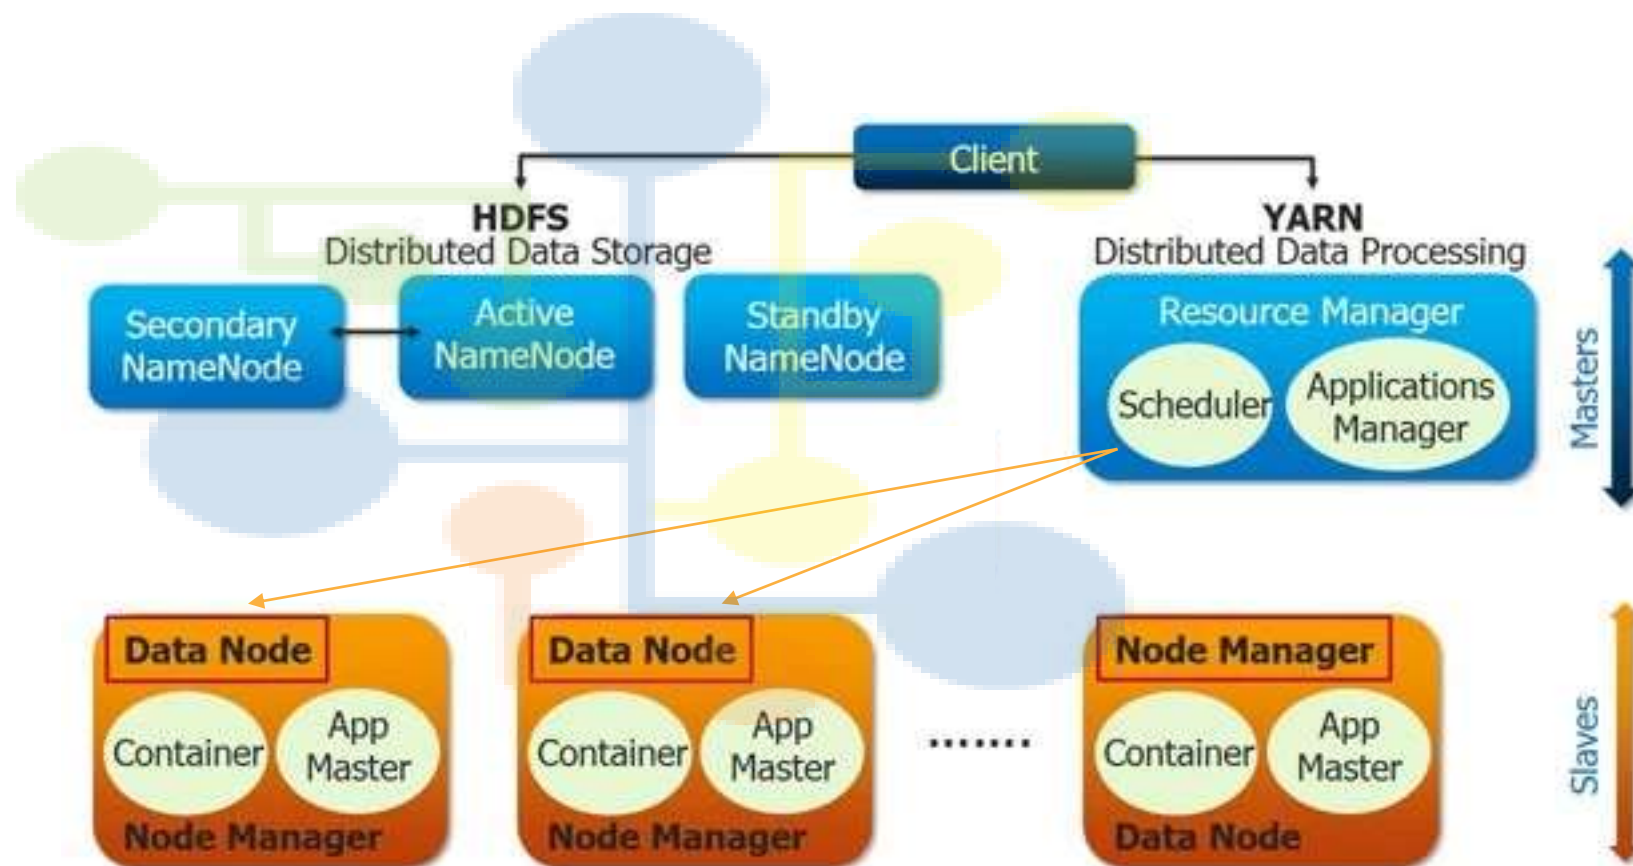
## Processo de Recuperação à Falha do NameNode





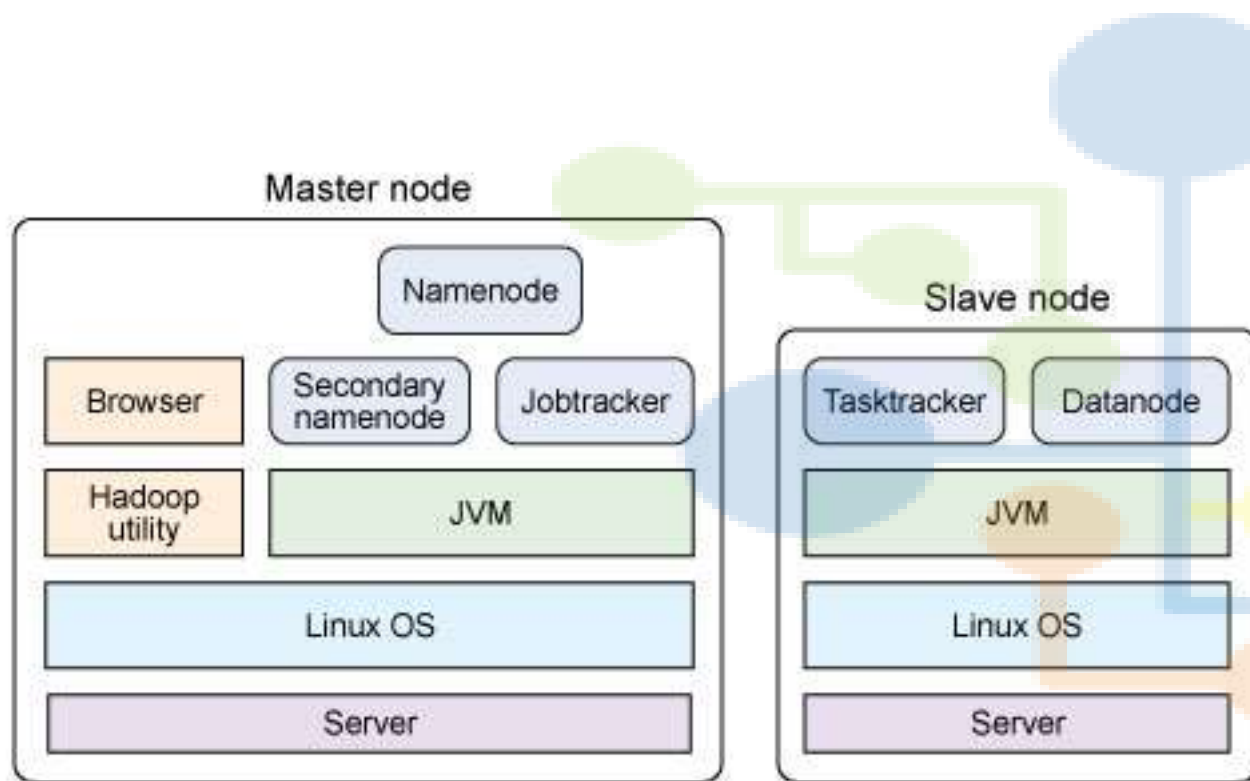
# Recuperação a Falhas

Processamento de  
Tarefas de Um Job  
MapReduce





# Recuperação a Falhas



O sucesso e segurança do processo de análise de Big Data com Hadoop, depende do bom funcionamento do Node Master



# Recuperação a Falhas

## Processo de Recuperação à Falha do NameNode

No caso de não haver backup do NameNode e o servidor falhar, o risco de perda de dados pode ser reduzido, criando um nível de redundância do NameNode

Faça uma cópia dos dados antes de promover o servidor a NameNode

Mude o endereço ip do novo servidor, para o endereço ip do servidor antigo

Garanta que o Hadoop esteja instalado e configurado de forma idêntica ao original

Não formate o NameNode



# Modo de Segurança



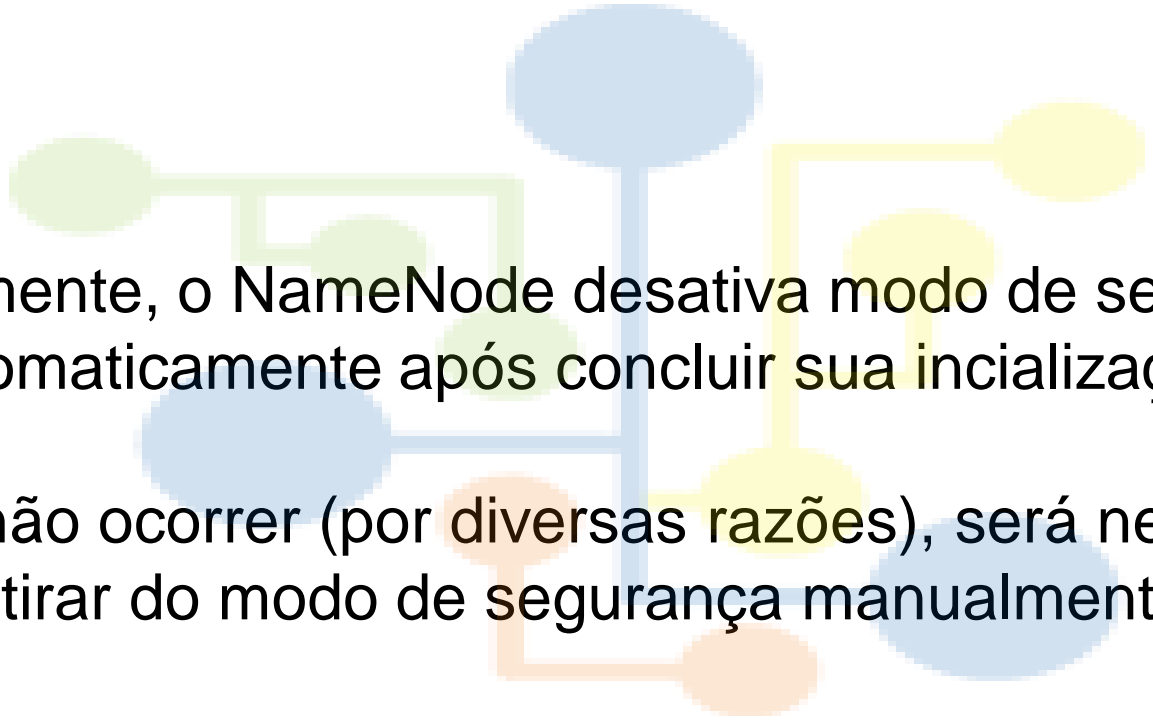


# Modo de Segurança

Modo de Segurança (Safe Mode) é o modo apenas leitura do cluster HDFS, onde modificações não são permitidas no file system ou nos blocos.



# Modo de Segurança

A faint, stylized diagram in the background consisting of several colored circles (blue, green, yellow, orange) connected by thin lines, resembling a network or organizational chart.

Normalmente, o NameNode desativa modo de segurança automaticamente após concluir sua inicialização.

Se isso não ocorrer (por diversas razões), será necessário retirar do modo de segurança manualmente.



# Modo de Segurança

## Safe Mode

Em Safe Mode:

- Somente operações no file system, que acessam os metadados podem ser executadas
- Leitura de arquivos serão possíveis apenas se os blocos estiverem disponíveis nos DataNodes
- Modificações em arquivos não serão efetivadas

Para colocar o HDFS em Safe Mode, use o comando:

```
hdfs dfsadmin -safemode
```

```
hdfs dfsadmin -safemode leave
```





# Backup


# Backup



Data Science  
Academy

Data Science Academy marcelo\_eidi12@hotmail.com 5d5c42d55e4cde68f38b457d

# Backup



# Backup



Data Science  
Academy

Data Science Academy marcelo\_eidi12@hotmail.com 5d5c42d55e4cde68f38b457d

No Hadoop o backup é composto de 2 partes:

- Backup dos metadados
- Backup dos dados

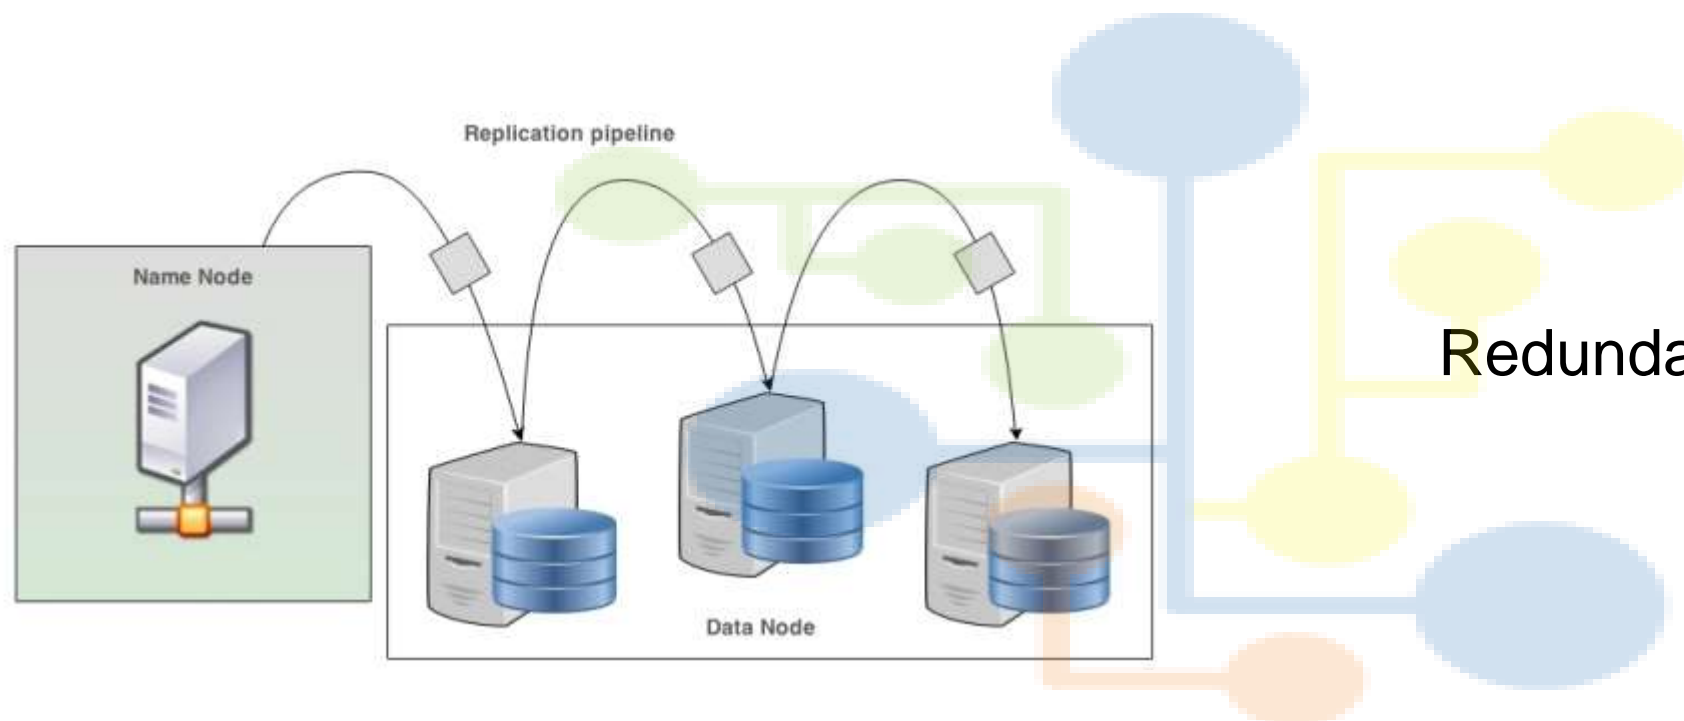


# Backup



Data Science  
Academy

Data Science Academy marcelo\_eidi12@hotmail.com 5d5c42d55e4cde68f38b457d




Redundante a Falhas por  
Padrão

# Backup



Data Science  
Academy

Data Science Academy marcelo\_eidi12@hotmail.com 5d5c42d55e4cde68f38b457d




Hadoop foi criado para executar  
em um único Datacenter

# Backup



Data Science  
Academy

Data Science Academy marcelo\_eidi12@hotmail.com 5d5c42d55e4cde68f38b457d



Hadoop permite o  
armazenamento de dados  
compactados

Parquet e ORC Files

## Backup do HDFS

Soluções  
Proprietárias

Replicação do  
HDFS

Cópia dos  
Dados


Dual Load

# Backup



Data Science  
Academy

Data Science Academy marcelo\_eidi12@hotmail.com 5d5c42d55e4cde68f38b457d





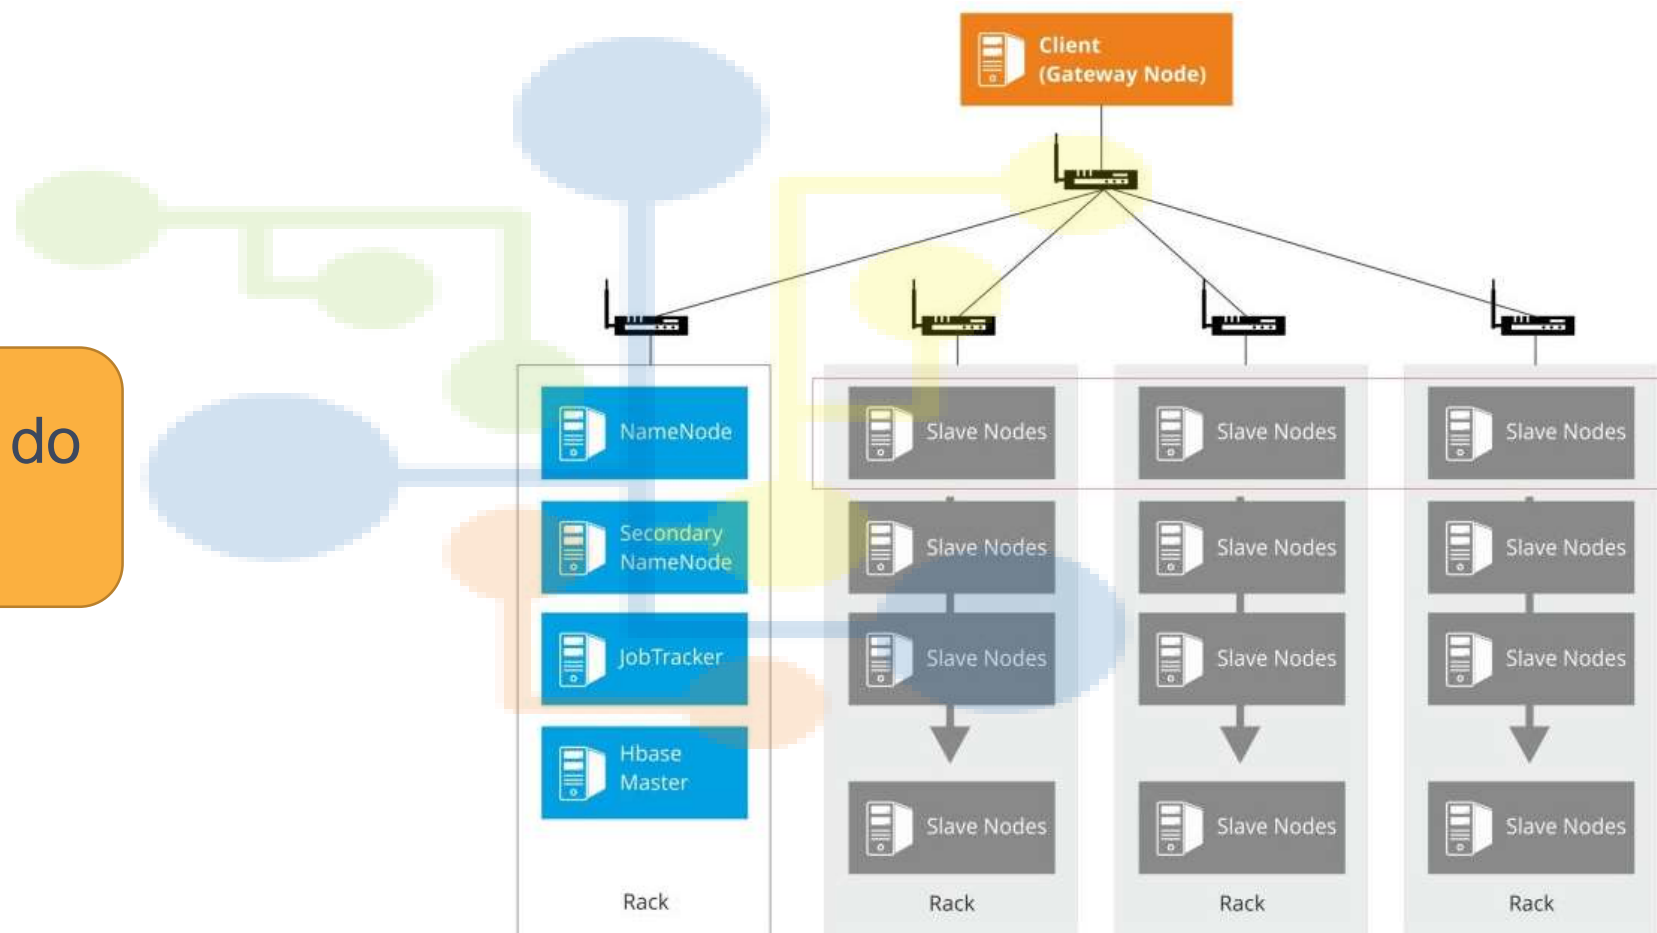
# Backup



Data Science  
Academy

Data Science Academy marcelo\_eidi12@hotmail.com 5d5c42d55e4cde68f38b457d

## Replicação do HDFS

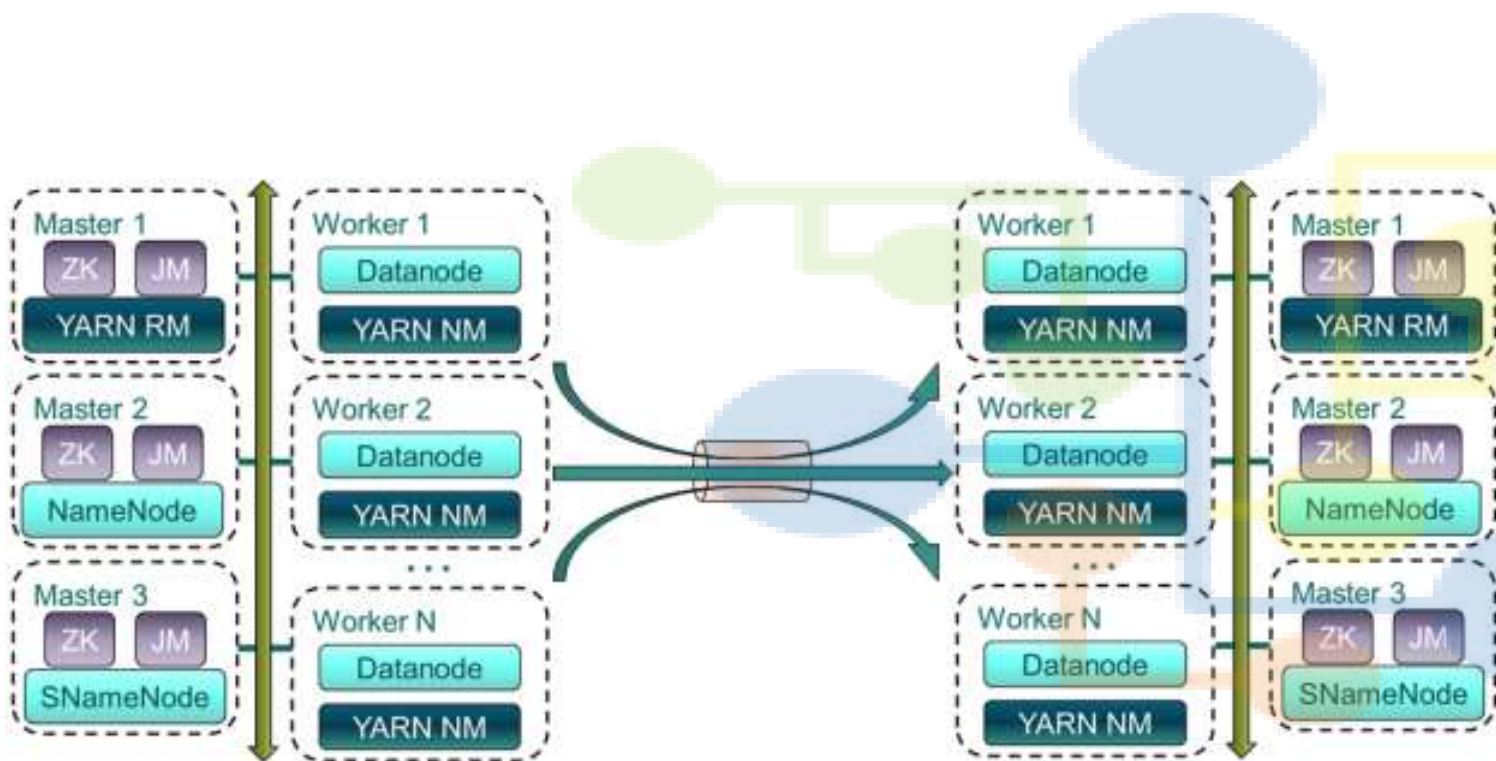


# Backup



Data Science  
Academy

Data Science Academy marcelo\_eidi12@hotmail.com 5d5c42d55e4cde68f38b457d



Cópia dos  
Dados

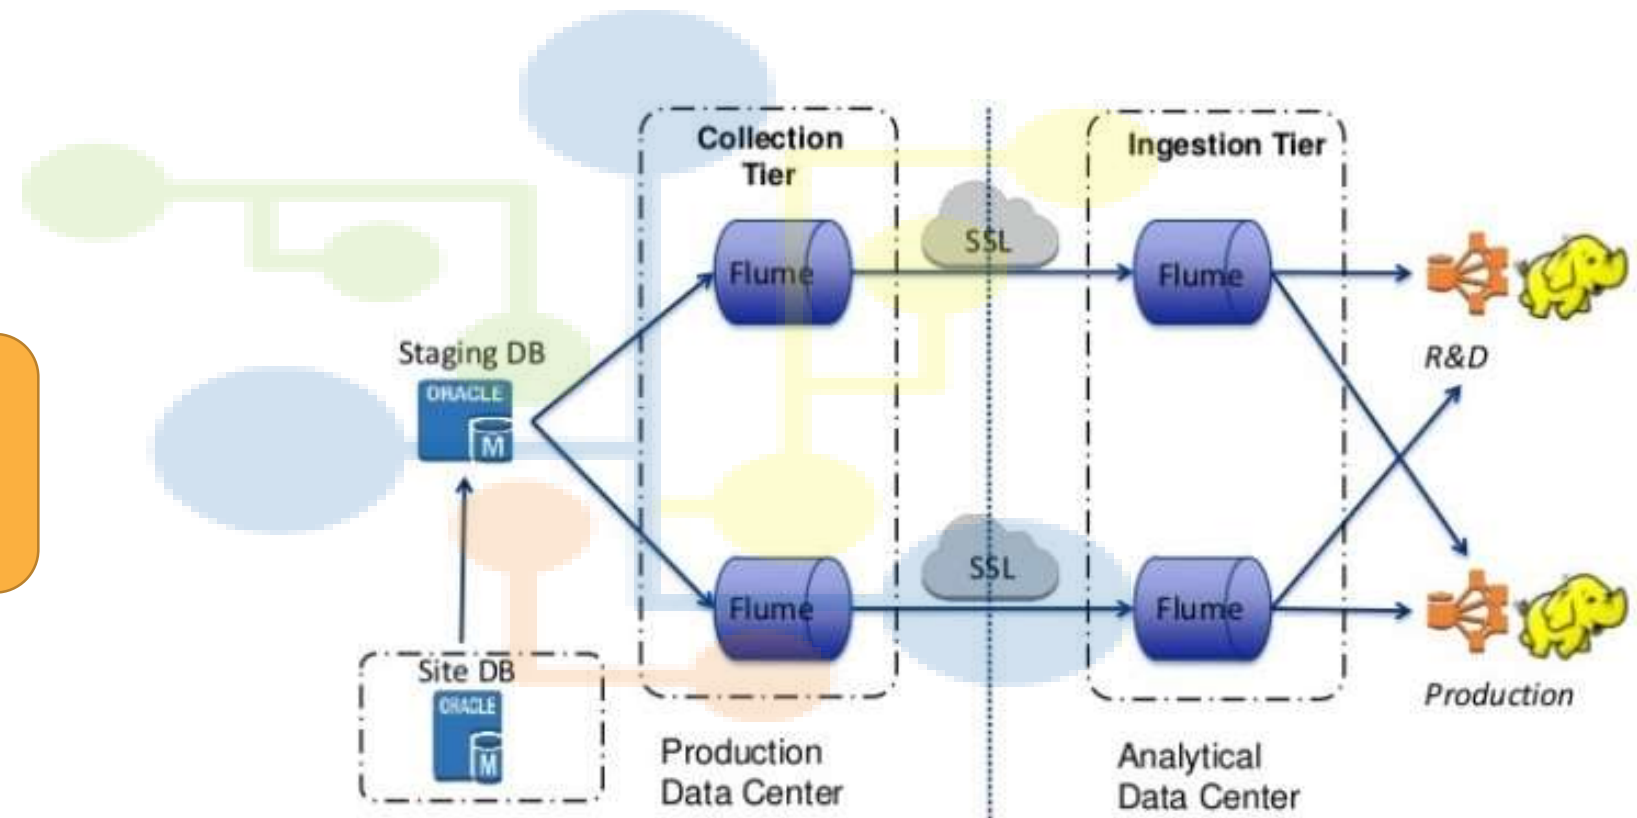
# Backup



Data Science  
Academy

Data Science Academy marcelo\_eidi12@hotmail.com 5d5c42d55e4cde68f38b457d

Dual Load




## Apenas o Backup é suficiente?

- Divisão dos dados em críticos e não críticos
- Formato do storage que será usado com o HDFS
- Monitoramento do Cluster
- Aplicação de Patches e Correções de Segurança

## Recovery

- Snapshots
- Replicação
- Recover Manual
- API



# Backup



Data Science  
Academy

Data Science Academy marcelo\_eidi12@hotmail.com 5d5c42d55e4cde68f38b457d

Filesystem check

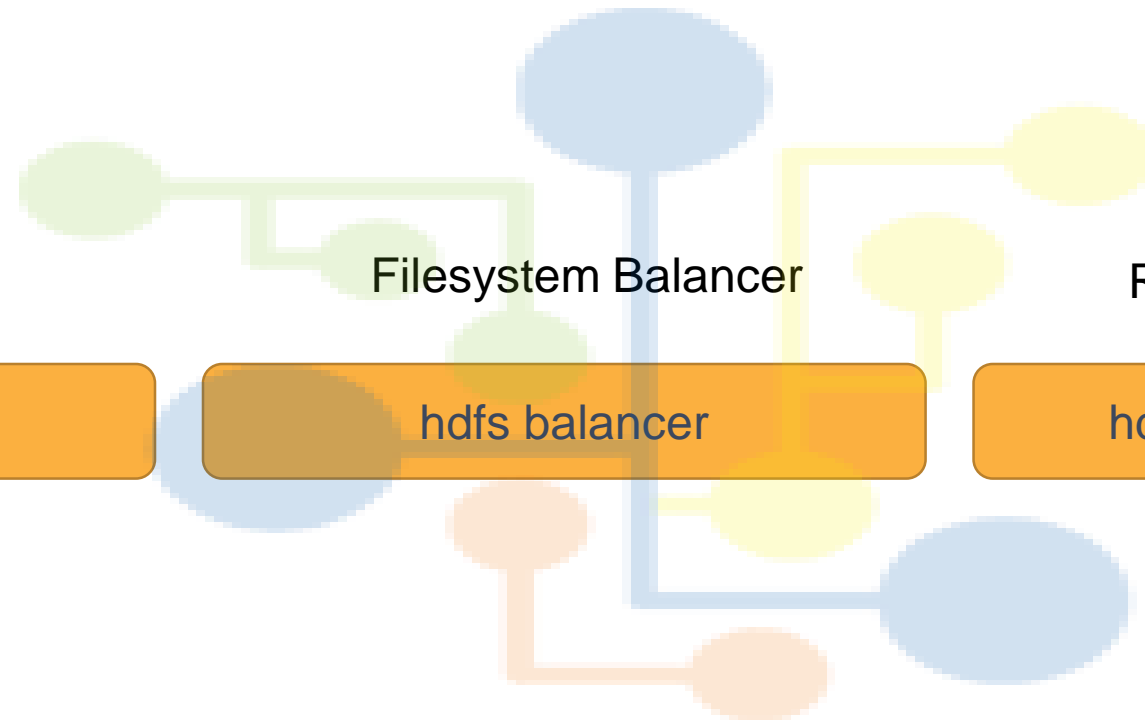
`hdfs fsck /`

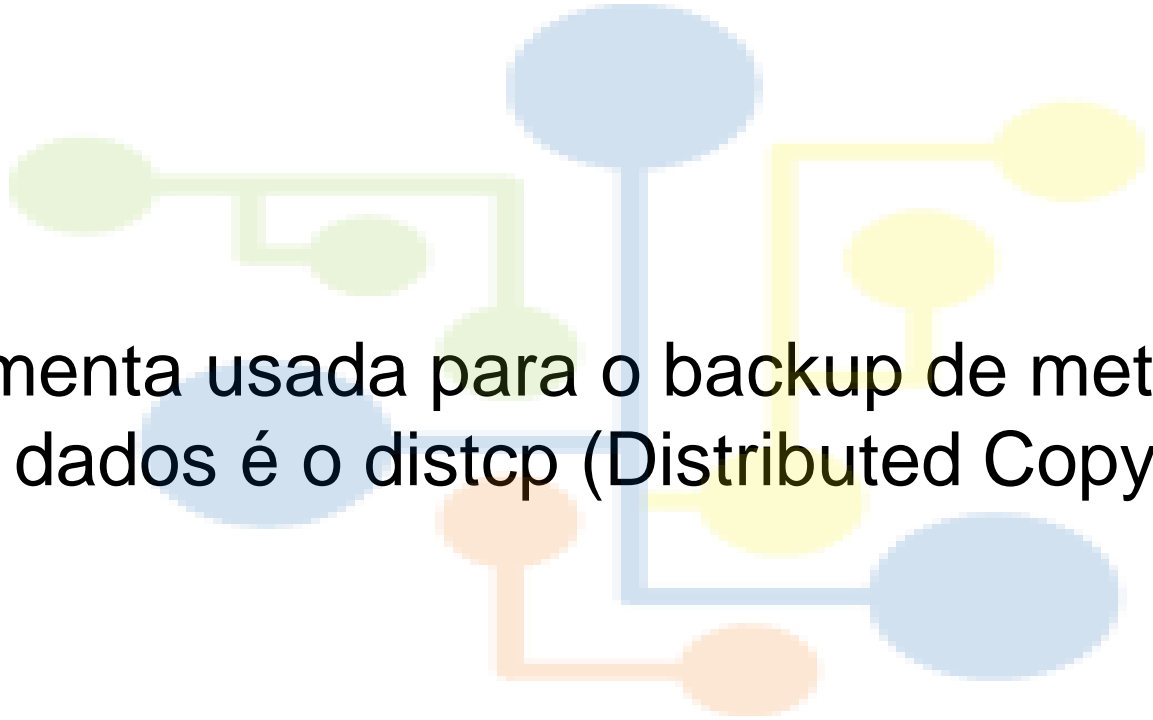
Filesystem Balancer

`hdfs balancer`

Relatório do cluster

`hdfs dfsadmin -report`



A faint, stylized network diagram in the background, consisting of several circular nodes connected by lines. The nodes are colored in light blue, light green, light yellow, and light orange. The lines are thin and colored to match the nodes they connect.


A ferramenta usada para o backup de metadados e dados é o distcp (Distributed Copy).

# Backup



Data Science  
Academy

Data Science Academy marcelo\_eidi12@hotmail.com 5d5c42d55e4cde68f38b457d

A faint, abstract diagram in the background consisting of several colored circles (blue, green, yellow, orange) connected by thin lines, suggesting a network or data flow.

Metadados dos demais produtos do ecossistema Hadoop, também devem ser incluídos no procedimento de Backup





# Solução de Problemas no Cluster Hadoop





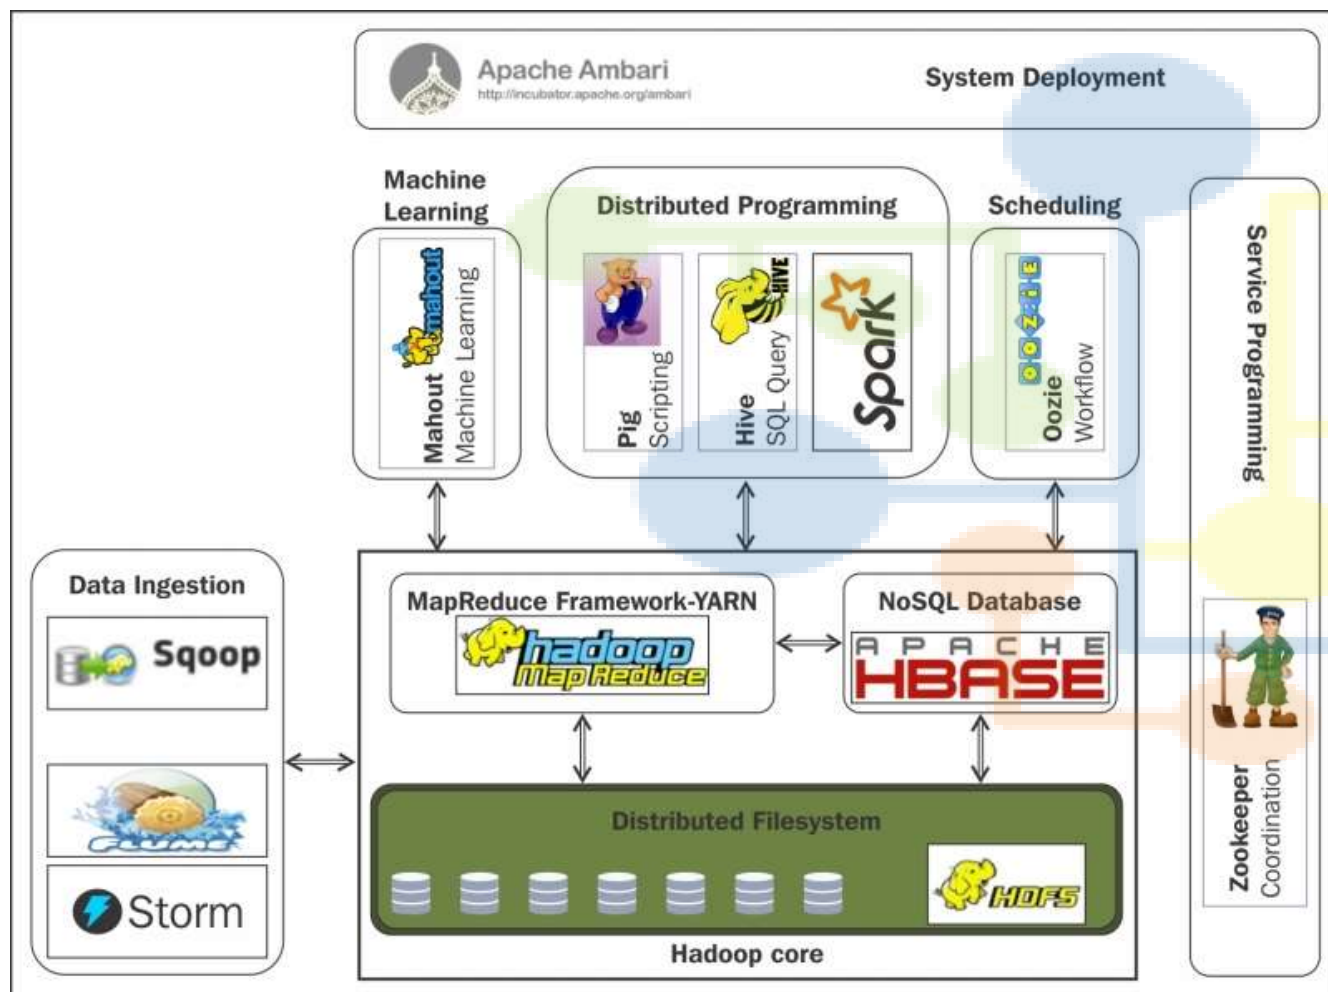
# Solução de Problemas no Hadoop

O Hadoop não é um banco de dados e na condição de repositório de dados, ele possui muitas vantagens em termos de gerenciamento e segurança





# Solução de Problemas no Hadoop



Hadoop é um grande ecossistema



# Solução de Problemas no Hadoop

## Possíveis problemas na Administração do Hadoop

### Erro humano

Erros humanos são uma das principais causas de problemas com o Hadoop

### Hardware

Falhas de disco ocorrem com frequência e nem sempre de uma vez. A degradação ao longo do tempo, pode levar à lentidão, antes de uma falha ocorrer

### Erros de configuração

É difícil configurar um ambiente Hadoop 100% otimizado e são muitos parâmetros possíveis. A utilização destes parâmetros depende de uma série de fatores por isso recomenda-se a realização maciça de testes antes de aplicar alterações em produção



# Solução de Problemas no Hadoop

## Possíveis problemas na Administração do Hadoop

Excessiva Utilização de Recursos

Erros em tarefas devem ser investigados e resolvidos. Erros recorrentes, consomem recursos do servidor, degradando performance

Identificação dos nodes

Configuração de rede dos nodes é um item crítico, pois a comunicação entre eles poderá gerar problemas de performance



# Solução de Problemas no Hadoop

## Solução de Problemas em um Ambiente Hadoop





# Autenticação e Segurança no Hadoop



# Autenticação e Segurança no Hadoop

## Riscos de Segurança no Armazenamento de Big Data

- Perda de Dados
- Queda de Produtividade
- Redução do Valor Geral dos Dados
- Vazamento de Dados Confidenciais

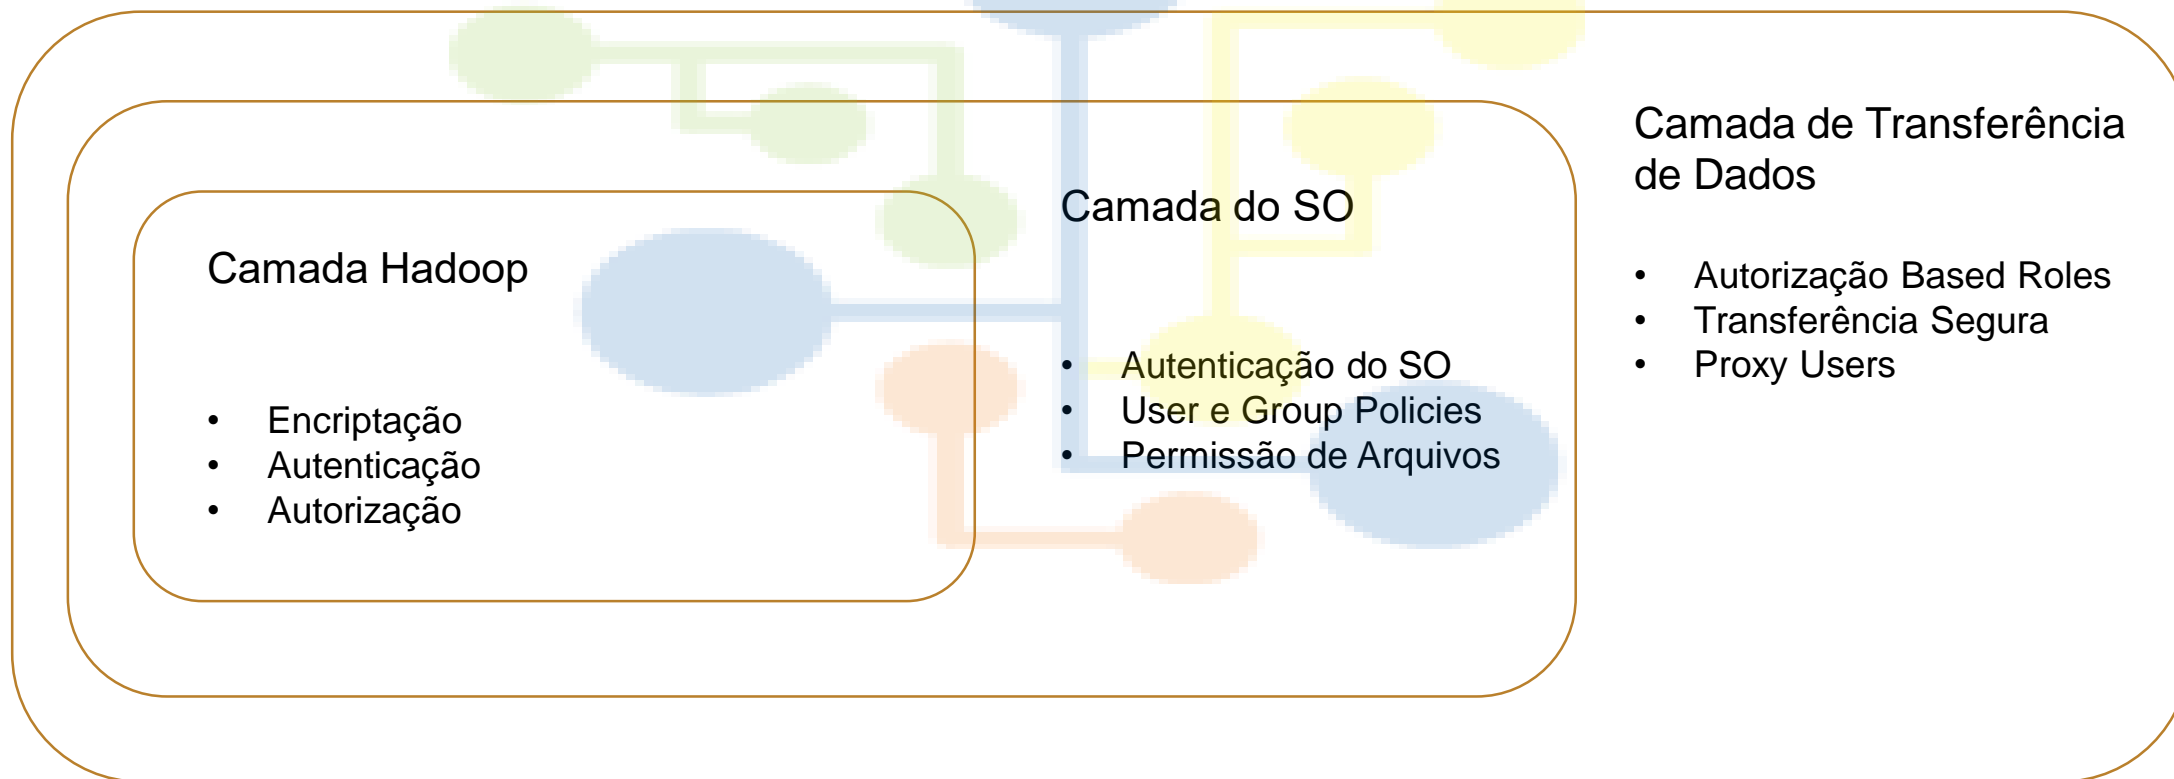






# Autenticação e Segurança no Hadoop

A segurança no Hadoop é feita através de múltiplas camadas





# Autenticação e Segurança no Hadoop

O Hadoop possui 2 métodos de autenticação





# Autenticação e Segurança no Hadoop

## Protocolo Kerberos



© Allison Smith, Amosink  
Interactive week



# Autenticação e Segurança no Hadoop

## Autenticação via Kerberos

Como funciona o Kerberos

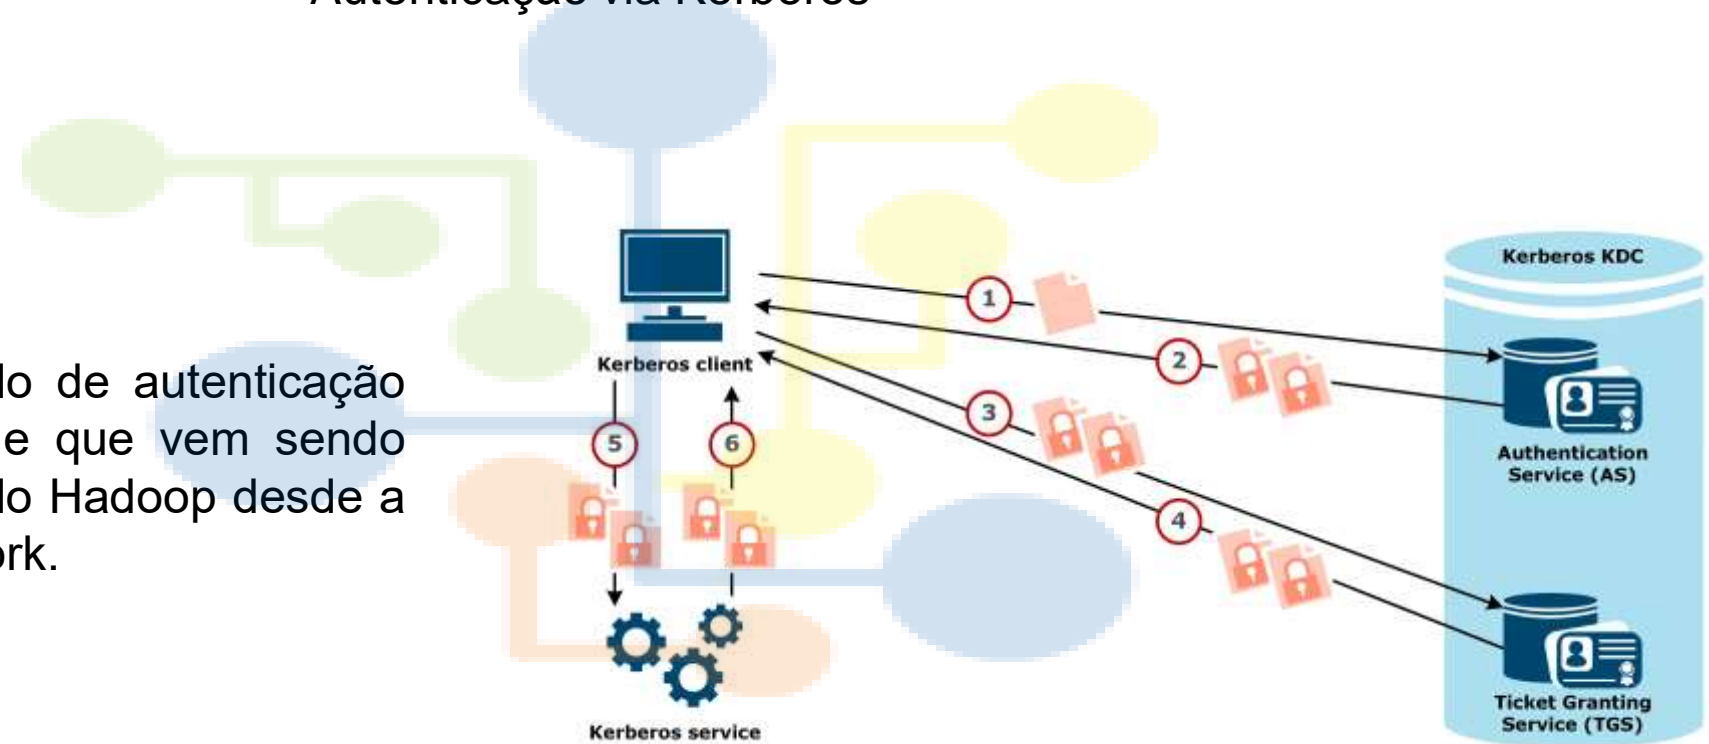




# Autenticação e Segurança no Hadoop

## Autenticação via Kerberos

Kerberos é um protocolo de autenticação de redes, open-source e que vem sendo usado na autenticação do Hadoop desde a versão 0.20 do Framework.

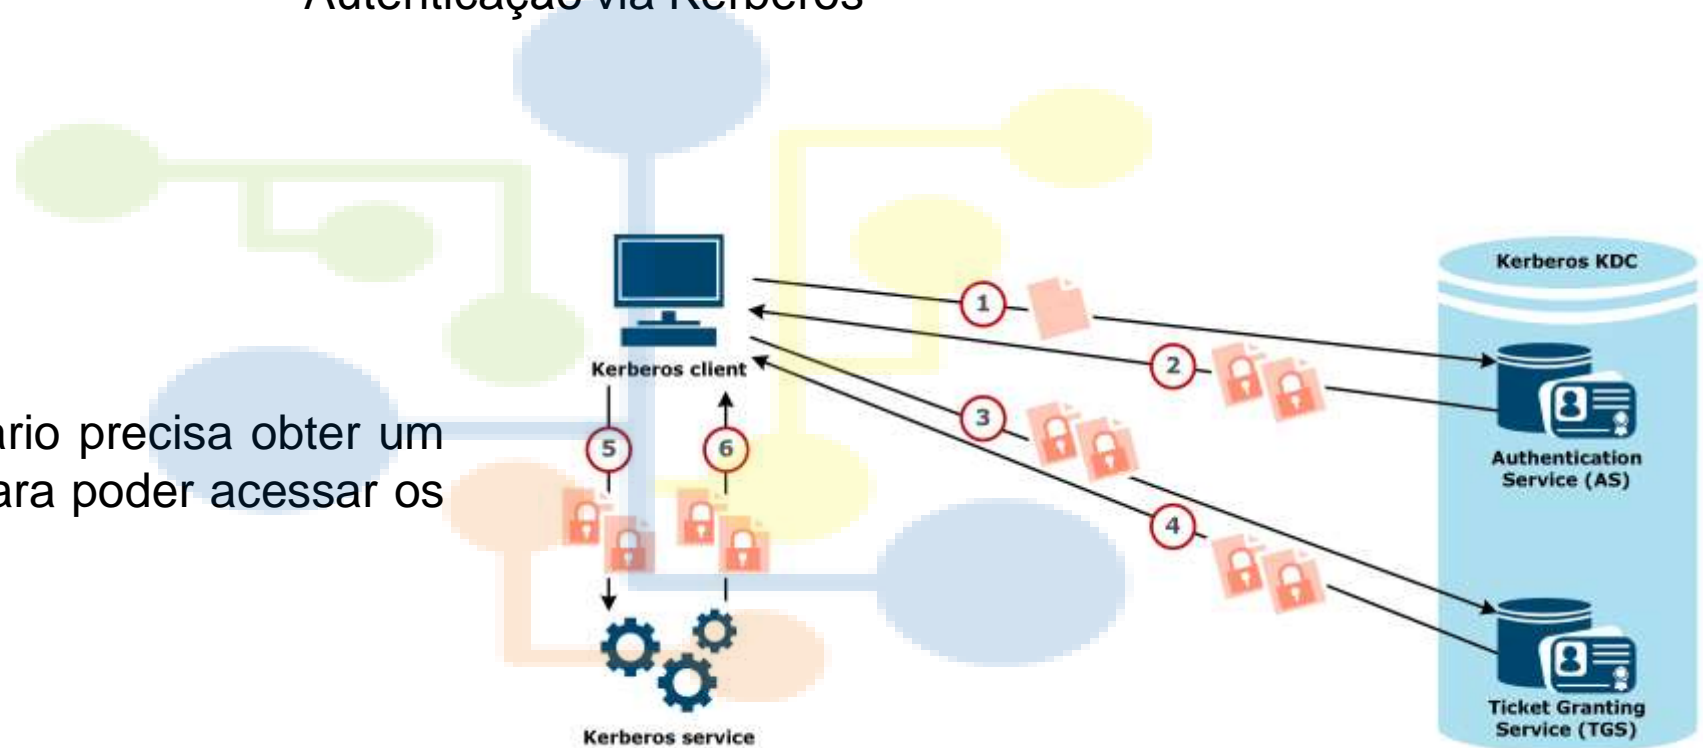




# Autenticação e Segurança no Hadoop

## Autenticação via Kerberos

Com o Kerberos, o usuário precisa obter um token de autenticação para poder acessar os dados no HDFS.





# Autenticação e Segurança no Hadoop

## Configuração do Kerberos

1

- Instalar os pacotes do Kerberos no sistema operacional
- `yum install krb5-server krb5-libs krb5-auth-dialog krb5-workstation`

2

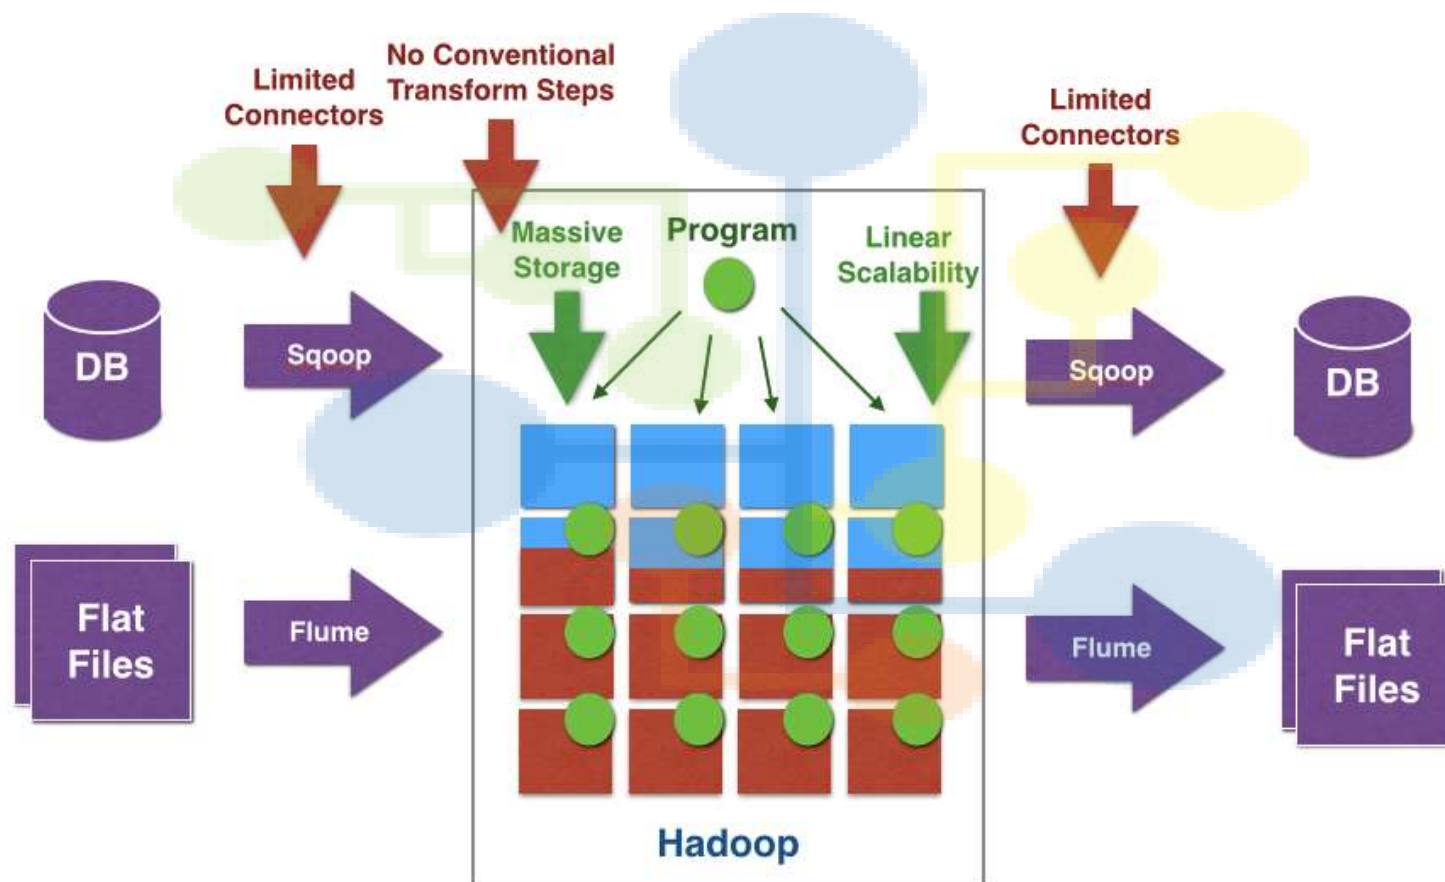
- Editar os arquivos de configuração
- `/etc/krb5.conf`
- `/var/kerberos/krb5kdc/kdc.conf`

3

- Copiar as versões atualizadas dos arquivos para cada node no cluster



# Autenticação e Segurança no Hadoop





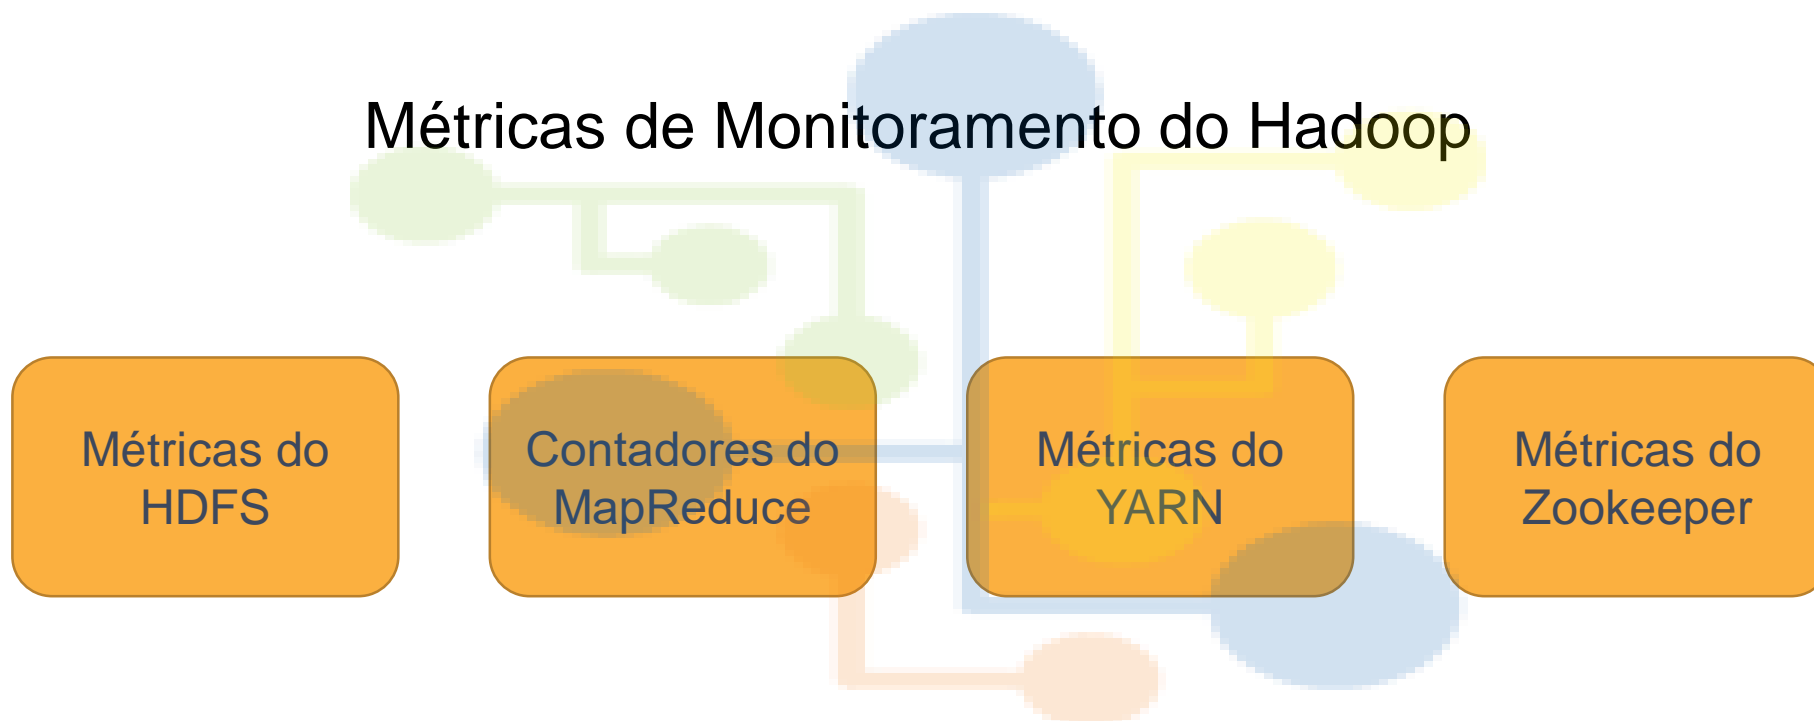


# Melhores Práticas de Monitoramento do Cluster Hadoop



# Monitoramento

## Métricas de Monitoramento do Hadoop



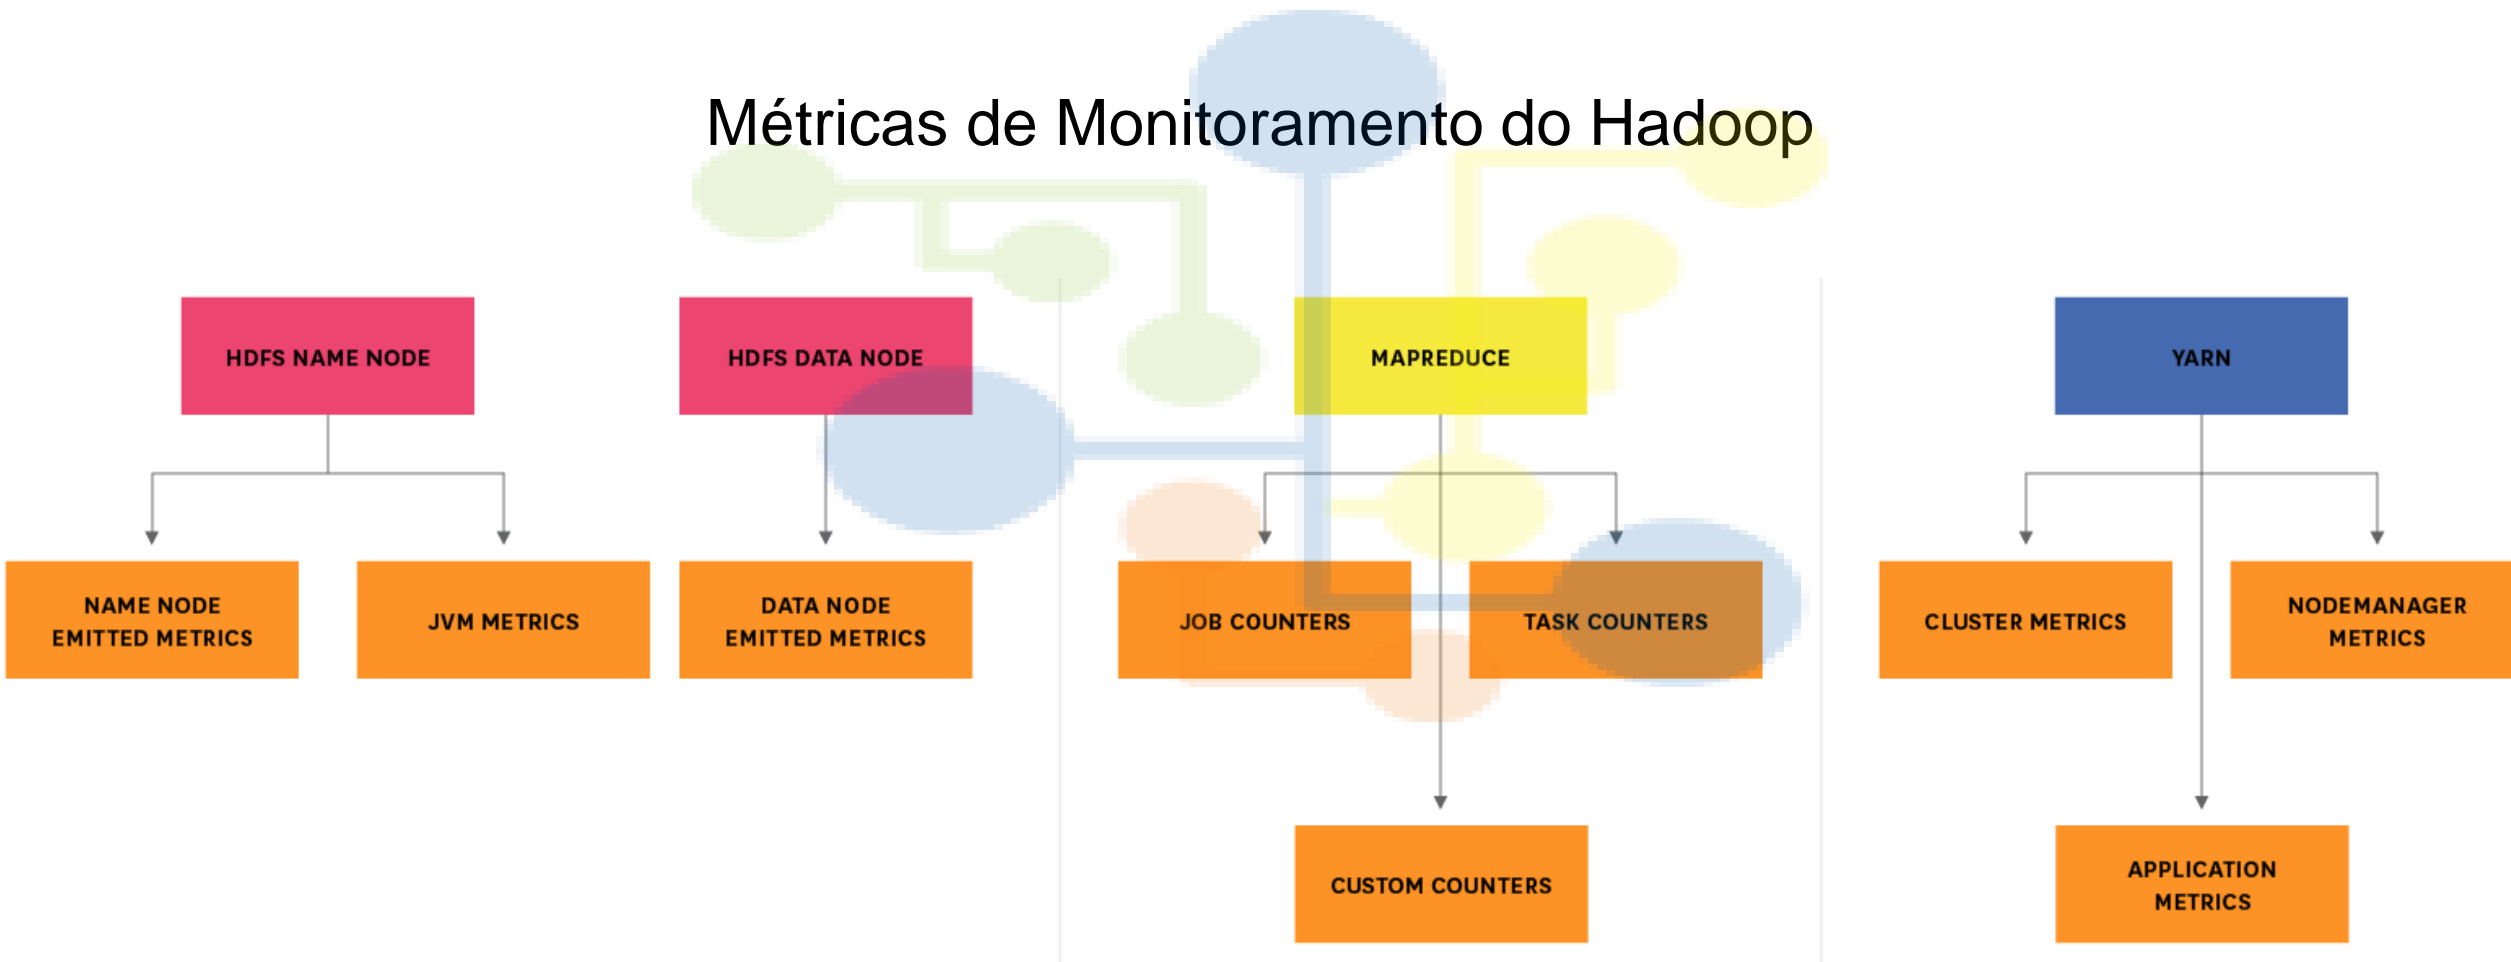
# Monitoramento



Data Science  
Academy

Data Science Academy marcelo\_eidi12@hotmail.com 5d5c42d55e4cde68f38b457d

## Métricas de Monitoramento do Hadoop






# Monitoramento

## Métricas HDFS

- NameNode metrics
- DataNode metrics

DataNodes se comunicam com o NameNode a cada 3 segundos  
(definido no parâmetro `dfs.heartbeat.interval`)





# Monitoramento

## Métricas HDFS

- NameNode metrics
- DataNode metrics

### Métrica a ser coletada

CapacityRemaining

CorruptBlocks / MissingBlocks

VolumeFailuresTotal

NumLiveDataNodes / NumDeadDataNodes

FilesTotal

TotalLoad

BlockCapacity / BlocksTotal

UnderReplicatedBlocks

NumStaleDataNodes

## Contadores MapReduce

- Job counters
- Task counters
- Custom counters
- File system counters

### Métrica a ser coletada

MILLIS\_MAPS/MILLIS\_REDUCES

NUM\_FAILED\_MAPS/NUM\_FAILED\_REDUCES

REDUCE\_INPUT\_RECORDS

SPILED\_RECORDS

GC\_TIME\_MILLIS

NUM\_FAILED\_MAPS

NUM\_FAILED\_REDUCES

RACK\_LOCAL\_MAPS

DATA\_LOCAL\_MAPS



# Monitoramento

## Métricas YARN

- Cluster metrics
- Application metrics
- NodeManager metrics

### Métrica a ser coletada

unhealthyNodes

activeNodes

lostNodes

appsFailed

totalMB / allocatedMB

progress

containersFailed



# Monitoramento

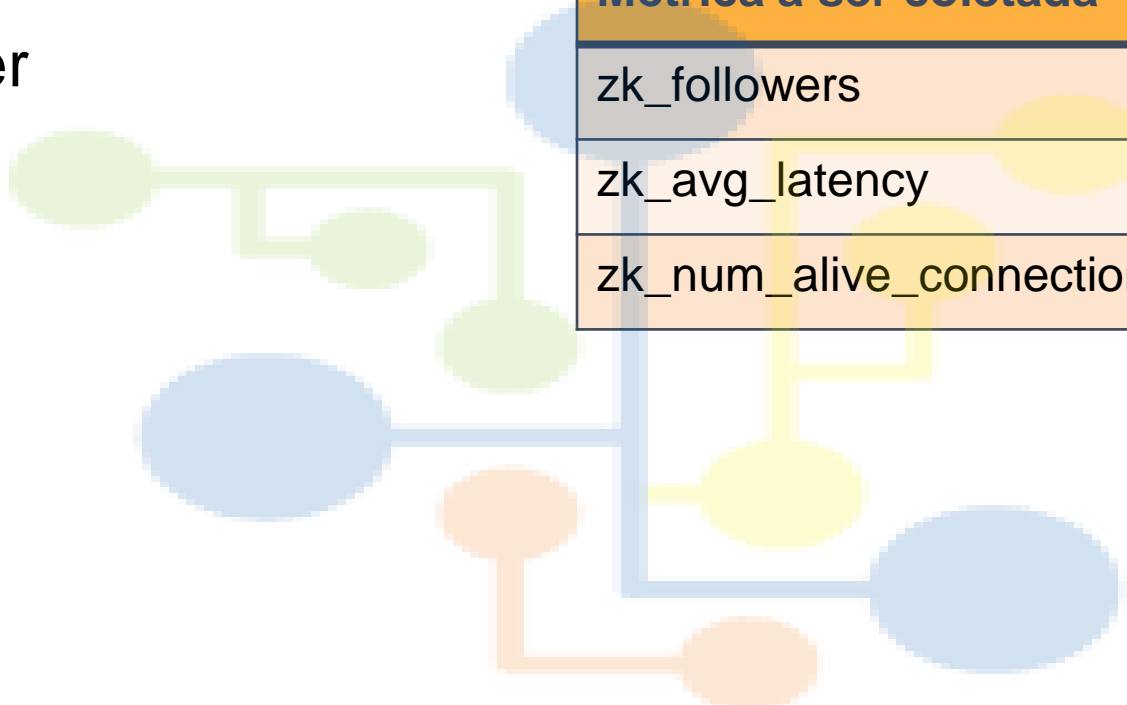
## Métricas Zookeeper

### Métrica a ser coletada

zk\_followers

zk\_avg\_latency

zk\_num\_alive\_connections







# Monitoramento

## Como coletar as métricas?

- NameNode → coleta de métricas via API
- DataNode → coleta de métricas via API
- HDFS → coleta de métricas via JMX



# Monitoramento

Como coletar as métricas?

- NameNode → coleta de métricas via API

`http://<namenodehost>:50070`



Como coletar as métricas?

- DataNode → coleta de métricas via API

<http://datanodehost:50070/dfshealth.html#tab-datanode>



# Monitoramento

Como coletar as métricas?

- HDFS → coleta de métricas via jmx


`http://<namenodehost>:50070/jmx`



# Monitoramento

Apache Ambari

Cloudera Manager





# Monitoramento

Apache Ambari

Utilizado pelo:


- Microsoft HDInsight
- Hortonworks

# Monitoramento



Data Science  
Academy

Data Science Academy marcelo\_eidi12@hotmail.com 5d5c42d55e4cde68f38b457d



# Monitoramento



Data Science  
Academy

Data Science Academy marcelo\_eidi12@hotmail.com 5d5c42d55e4cde68f38b457d

Dashboard





# Monitoramento



Data Science  
Academy

Data Science Academy marcelo\_eidi12@hotmail.com 5d5c42d55e4cde68f38b457d

## Grupos de Alerta

### Manage Alert Groups

You can manage alert groups for each service in this dialog. View the list of alert groups and the alert definitions configured in them. You can also add/remove alert definitions, and pick notification for that alert group.

AMBARI Default (44)	Metric Collector HBase Maser CPU Utilization
AMS Default (44)	Metric Collector - HBase Master Process
HDFS Default (44)	Metric Collector Process
HIVE Default (44)	Metric Monitor Status
KAFKA Default (44)	Percent Metric Monitors Available
MAPREDUCE2 Default (44)	Metric Collector - ZooKeeper Server Process
OOZIE Default (44)	History Server Web UI
PIG Default (44)	History Server Process
SQOOP Default (44)	History Server RPC Latency
TEZ Default (44)	History Server CPU Utilization
YARN Default (44)	Secondary NameNode Process
ZOOKEEPER Default (44)	NameNode High Availability Health
	DataNode Web UI
	NameNode Host CPU Utilization
	NameNode RPC Latency

☒ Notifications

Add

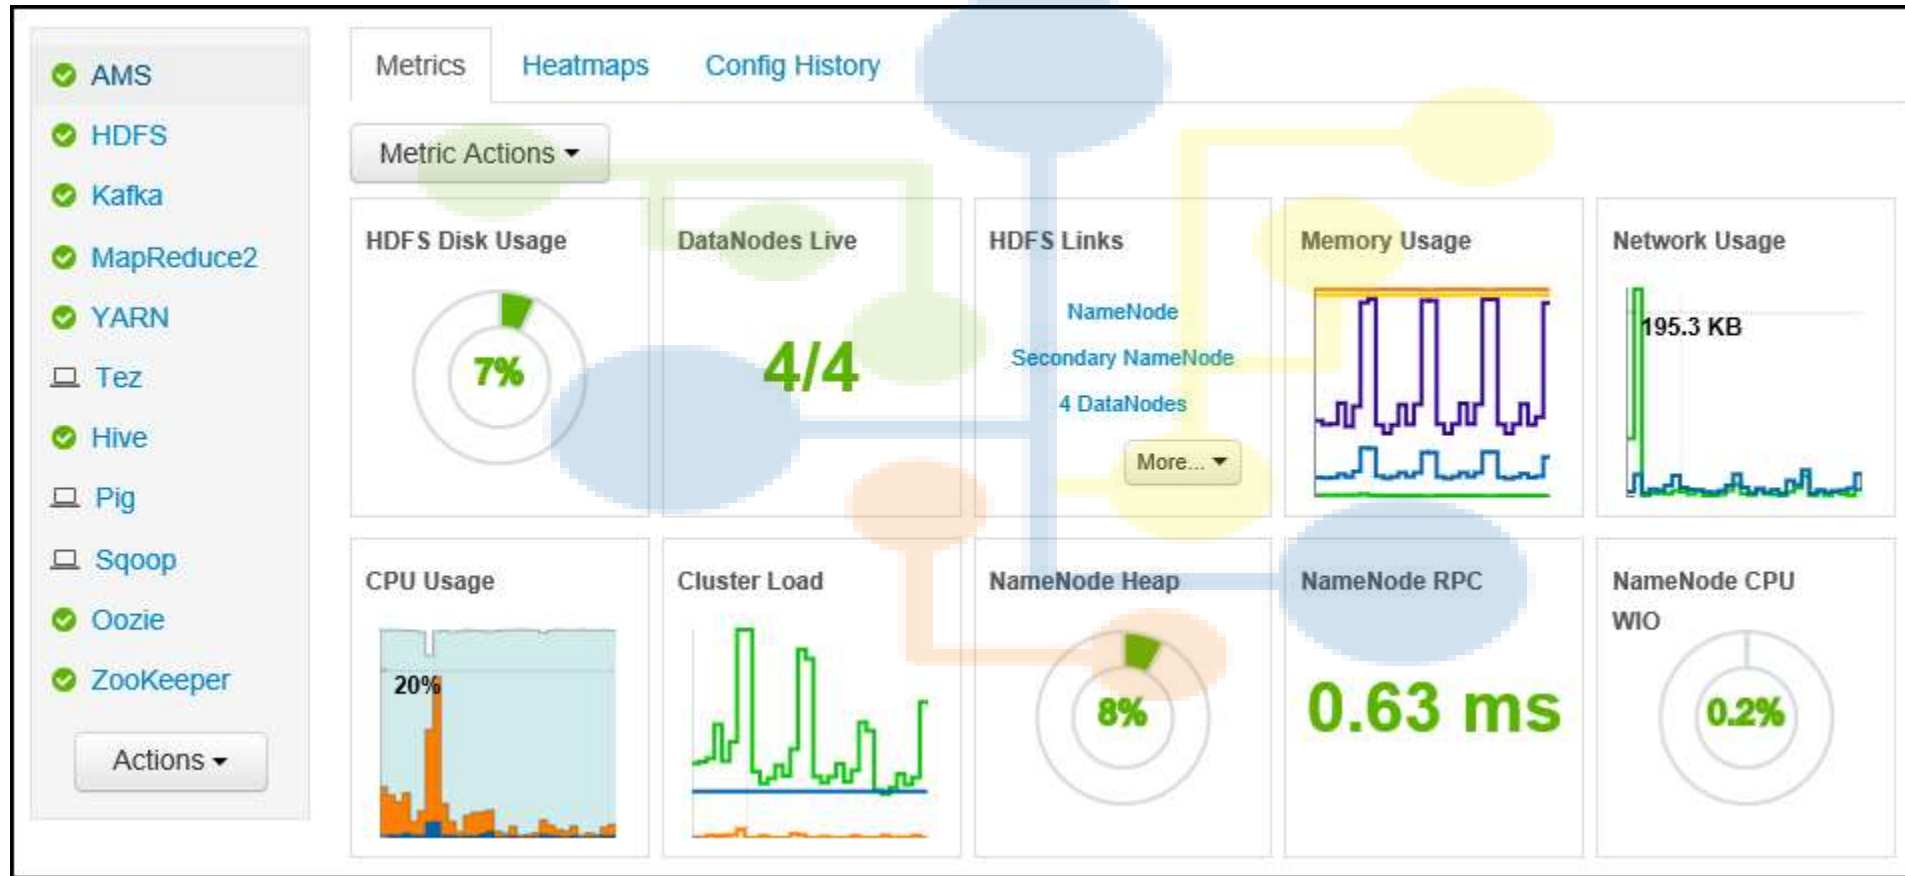
Cancel Save

# Monitoramento



Data Science  
Academy

Data Science Academy marcelo\_eidi12@hotmail.com 5d5c42d55e4cde68f38b457d





# Obrigado

---

